

硕士学位论文

激光雷达和多相机融合的智能标定方法研究

**RESEARCH ON INTELLIGENT CALIBRATION
METHOD OF LIDAR AND MULTI-CAMERAS
FUSION**

王晨宇

哈尔滨工业大学

2019 年 6 月

国内图书分类号：TP242.2

学校代码：10213

国际图书分类号：621.38

密级：公开

学术硕士学位论文

激光雷达和多相机融合的智能标定方法研究

硕 士 研 究 生：王晨宇

导 师：费中阳

申 请 学 位：工学硕士

学 科：控制科学与工程

所 在 单 位：航天学院

答 辩 日 期：2019 年 6 月

授予学位单位：哈尔滨工业大学

Classified Index: TP242.2

U.D.C: 621.38

Dissertation for the Master Degree in Engineering

**RESEARCH ON INTELLIGENT CALIBRATION
METHOD OF LIDAR AND MULTI-CAMERAS
FUSION**

Candidate:	Wang Chenyu
Supervisor:	Prof. Fei Zhongyang
Academic Degree Applied for:	Master of Engineering
Speciality:	Control Science and Engineering
Affiliation:	Aerospace Institute
Date of Defence:	June, 2019
Degree-Conferring-Institution:	Harbin Institute of Technology

摘 要

自动驾驶技术是当下的热门话题，其中感知模块是非常重要的一环，起到承上启下的作用。在感知模块中最重要的应该是处理从传感器中接收到的数据了。目前多种传感器的融合是大势所趋，本课题中的实验平台是应用到感知模块中的两种传感器。实验平台是由一个激光雷达和五个相机组成，本课题的工作是完成平台使用前激光雷达和五个相机的外参标定，以及相机的内参标定。本文主要研究工作如下：

（1）实验平台的搭建，标定数据的采集、同步和筛选。首先根据需要设计平台的机械结构，接着使用生成的随机噪声标定板绕着多相机平台移动一圈，使用棋盘格标定板在相机视野的九个位置采集 90 个位姿图像。接着使用 ROS 系统中的 `message_filters` 对数据进行同步，并对图片数据中的无效图片进行剔除。

（2）多相机平台中相机间的外参和相机的内参标定方法研究。首先对比了图像特征点检测几种方法，选择最适合标定的 SURF 检测方法。通过特征点检测和匹配将拍摄到的标定板图像和生成的标定图像建立联系，利用空间对应平面的单应性通过匹配到的特征点计算出单应矩阵。分解单应矩阵得到标定板在相机坐标系中的位置和姿态以及相机的内参。使用最小重投影误差优化相机内参以及标定板的位置和姿态。最后通过图优化的方法利用相邻相机同时拍到的标定板的位姿完成相机间的外参标定。

（3）激光雷达和相机外参标定方法研究。截取每个位姿的点云和相应帧的图像，在点云中选择打在标定板上的点云，估计出标定板所在激光雷达检测数据中的位姿，以及平面法向量的矩阵。在标定图片中使用角点检测等方法计算出内角点的像素坐标，通过对应角点的坐标计算出标定板在相机坐标系中的位置和姿态及其法向量的方向矩阵。通过两个坐标系中的法向量矩阵计算出旋转矩阵，并通过最小化点云到平面的距离优化出平移向量，联立完成激光雷达与相机外参标定。

（4）将相机间的外参和激光雷达与相机间的外参联合，完成系统的标定。

关键词：标定；激光雷达；多相机；外参；内参

Abstract

The technology of driverless car is a hot topic at the moment, and the perception components is a very important part, which plays a role in linking up and down. The most important thing in the perception components is the data received from the sensor. At present, the fusion of various sensors is the trend of times. The experimental platform in this subject is the two sensors applied to the perception components. It consists of a LIDAR and five cameras. The work of our project is to complete the extrinsic calibration of the LIDAR and five cameras before the platform is used, as well as the intrinsic calibration of the camera. The main research work of this paper are as follows:

(1) The construction of the experimental platform, the collection, synchronization and screening of calibration data. First, design the mechanical structure of the platform , then use the generated random noise pattern to move around the multi-camera platform . And use the checkerboard calibration pattern to capture 90 pose images at nine positions in the camera's field of view. Then use the message_filters in the ROS system to synchronize the data and eliminate the invalid images in the calibration image data.

(2) Research on calibration methods of multi-camera platform's extrinsic and intrinsic. Firstly, several methods of image feature points detection are compared. And the SURF detection method which is most suitable for calibration is selected. The pattern image is associated with the generated calibration image by feature points detection and matching. And the homography matrix is calculated by matching the feature points with the homography of the spatial corresponding plane. Decompose the homography matrix to get the pose of the pattern in the camera coordinate system and the intrinsic of the camera. Optimize the pose of the camera intrinsic and pattern using minimum reprojection error. Finally, the extrinsic is completed by the graph optimization by using the pose of the pattern by the adjacent cameras.

(3) Research on LIDAR and camera extrinsic calibration methods. Intercept the

point cloud of each pose and the pattern of the corresponding frame. Select the point on the pattern in the point cloud, calculate the pose of the pattern in the LIDAR coordinate system by least squares algorithm and its normal vectors. In the image, the pixel coordinates of the inner corner points are detected by the method of corner detection, and the pose of the pattern in the camera coordinate system and its normal vector are calculated by the corresponding corner points. The rotation matrix is calculated by the normal vector in the two coordinate systems, and the translation vector is calculated by minimizing the distance from the point to the pattern. Finally, the extrinsic of the LIDAR and the camera is completed.

(4) The extrinsic between the multi-cameras and LIDAR are combined to complete the calibration of the entire system

Keywords: Calibration, LIDAR, Multi-Cameras, Extrinsic, Intrinsic

目 录

摘 要	I
ABSTRACT	II
目 录	IV
第 1 章 绪 论	1
1.1 课题来源及背景	1
1.1.1 课题来源	1
1.1.2 课题背景及意义	1
1.2 研究现状	4
1.2.1 相机标定研究现状	4
1.2.2 单相机和三维激光雷达外参标定研究现状	5
1.3 本文主要研究内容及章节安排	7
1.3.1 研究内容	7
1.3.2 章节安排	8
第 2 章 多相机与激光雷达标定数据采集	10
2.1 引言	10
2.2 多相机和激光雷达平台简介	10
2.3 标定图像的选择和生成	12
2.3.1 图像的特征点检测	12
2.3.2 SIFT 算法和 SURF 算法	12
2.3.3 多相机平台标定图像生成	14
2.3.4 单相机和激光雷达标定板选择	15
2.4 标定数据采集	16
2.4.1 标定数据采集软件	16
2.4.2 多相机标定数据采集	17
2.4.3 单相机和激光雷达标定数据采集	18
2.5 本章小结	19
第 3 章 多相机平台标定	21
3.1 引言	21

3.2 单相机标定	21
3.2.1 针孔相机模型	21
3.2.2 相机畸变模型	23
3.2.3 单相机标定	25
3.3 多相机标定	35
3.4 本章小结	40
第 4 章 单相机和激光雷达标定及联合标定	41
4.1 引言	41
4.2 激光雷达基本原理	41
4.3 确定点云中标定板平面	43
4.4 确定图像中标定板平面	47
4.5 联合外参	57
4.6 本章小结	59
结 论	61
参考文献	62
致 谢	67

第1章 绪 论

1.1 课题来源及背景

1.1.1 课题来源

本课题来源于智能控制系统研究所与速腾聚创联合实验室的研究题目。本课题使用的实验平台是应用在汽车自动驾驶上，为汽车在自动驾驶状态下感知周围环境以及进行局部路径规划提供多个角度的图像数据以及激光雷达探测到的点云数据。在使用相机前需要对相机进行内参标定，为了将多相机以及激光雷达之间建立联系，需要进行多个传感器之间的外参标定。因此，根据课题需要完成激光雷达和多相机之间的外参标定，以及每个相机的内参标定。



图 1-1 实验设备

1.1.2 课题背景及意义

自动驾驶技术是从人类发明汽车并逐渐量产普及过程中一直在追求和努力实现的一个领域。在封神榜的小说中就提到了能听懂人说话，自动行驶的木车，体现了人类对于车辆自动驾驶的向往。在上世纪 80 年代，自动驾驶相关技术得到了飞速发展，世界上第一辆自主行驶导航车辆由外国团队研发成功，在预先设定的

轨道中车辆可以自动行驶^[1]。近年来随着计算机科学和人工智能领域的发展和逐步完善，自动驾驶技术再一次进入高速发展的道路上。完整的自动驾驶技术可以分为：构建高精度地图；车辆初始状态及行驶状态中定位；车辆对周围环境的感知技术；对周围环境可能发生的情况的预测；基于感知和预测的局部路径规划；基于起始点和终点的全局路径规划；将局部路径规划的结果转换成控制信号对车辆进行控制。以上自动驾驶的六个部分都需要通过接收传感器的各种信息并进行处理之后才能使用。例如最先实现 L3 级自动驾驶电动车量产的特斯拉（Tesla）^[2]，该公司的多传感器解决方案就是应用 8 个摄像头和 12 个超声波传感器。




图 1-2 特斯拉硬件解决方案

目前特斯拉已经实现在特定的环境下自动驾驶。除了像特斯拉这样全部以摄像头作为感知的主传感器外，还有类似速腾聚创的以三个激光雷达作为感知解决方案。速腾聚创的感知模块的解决方案命名为 P3 方案，该方案采用 2 个 16 线加上 1 个 32 线激光雷达的数据融合。多激光雷达可以相互补盲，提高点云的密度，确保感知系统冗余性和探测精度。

近些年，Google 前后开发出多辆自动驾驶汽车。Google 的无人驾驶汽车的感知方案使用了摄像头和激光雷达两种传感器融合的方式感知其他车辆，并通过事先已经建立好的高清地图进行导航^[3]。



图 1-3 速腾聚创感知解决方案

从 2013 年起，百度开始研发自动驾驶项目，两年之后百度的无人车已经可以初步在道路上自动行驶，且全程最高时速 100 公里每小时。同时百度也开源了自己的无人驾驶解决方案 Apollo^[4]，该方案中提及了百度的自动驾驶套件中的硬件配置。其中使用了 3 个激光雷达、1 个双目摄像头和 5 个单目摄像头。



图 1-4 谷歌和百度无人驾驶车

从所举的自动驾驶的例子中可以看出，除了特斯拉之外其他几家厂商都会在自动驾驶的硬件配置中加入激光雷达。随之自动驾驶技术研究的深入，就目前来看很多研究结果表明使用单一的传感器进行感知是有弊端的。例如在黑夜、雾霾天气、大雨天气或者是强反光等，特斯拉曾因为强反光错误识别大货车侧面导致了事故。因此，目前在做 L4 级别的自动驾驶解决方案的研发机构大部分都采用多种传感器融合的方案^[5]。

相机在自动驾驶中可以提供丰富的彩色信息，通过视觉 SLAM 方法可以构建出有深度的彩色地图，并可以利用相机采集到的图像和已经建好的彩色地图匹配进行定位^[6]。但是，相机的缺点是容易受光照的影响。在光照变化明显的地方，例如进入隧道或者从隧道中出去，在这两个阶段光照变化非常剧烈，使用图像识别会有错误出现。并且由于相机的垂直视角有限，单个摄像头无法对车辆全方位的

拍摄。因此，本课题中使用了五个摄像头保证可以对车辆 360° 拍摄。

激光雷达可以探测到几十米外的物体，本课题中选择的 32 线激光雷达最远分辨率可以达到 200 米，而感知系统可以识别多远的物体决定了车辆可以开多快。同时激光不受光照、强反光等影响，但是激光雷达的缺点是由于其工作方式是发射一道道激光并检测激光的反射光。因此，激光雷达检测到的点云数据是稀疏的、无序的、不均匀分布的，而更高线程的激光雷达的成本会成倍的增长，并且相对于相机拍摄到的图像即使更高线程的点云数据还是稀疏的。因此，激光雷达和多相机的融合的意义在于两种传感器取长补短，各自发挥优势，可以为感知模块提供丰富的彩色图像信息和准确的位置点云信息。

本课题的意义在于在设计一个方法解决对两种传感器使用和融合前需要对相机的内参标定，内参是将空间点从全局坐标系向相机的像素坐标系变换的系数矩阵。同时对相机间的外参变换矩阵、相机和激光雷达的外参变换矩阵进行标定。因为，进行融合时需要知道相机和激光雷达的空间位置关系。为了方便标定，本课题还设计了一个可视化软件简化标定过程。

1.2 研究现状

多相机的标定以及相机和激光雷达标定是一个很重要的内容，因为所有传感在使用之前都需要进行标定。有的是购买时厂家会提供标定好的参数，如果没有提供就需要自己标定。根据本课题的实验平台的特点我们将其分成两个部分调研，一个是相机的内参和多相机间的外参标定，另一部分是单个相机和平台中间的激光雷达之间进行外参标定。

1.2.1 相机标定研究现状

目前由于计算机视觉的快速发展，已经有很多针对相机内参标定的方法。这些方法主要可以分成两大类：一种是使用特殊的目标并使用相应的算法进行标定；另一种是相机的内参自标定。本课题中使用的是前一种内参标定方法，因为使用特殊的标定目标用来标定通常比自标定方法更准确。在相机内参系数计算中，使用最广泛的就是张正友教授的使用棋盘格进行相机内参标定^[7]。受张正友教授的方法启发，很多开源的库函数例如 OpenCV 以及一些工具箱^[8, 9]都使用该方法进行开发和标定。对于普通的单目相机，D. Scaramuzza 等人^[10]发明了一种工具箱，该工

具箱使用多项式来拟合每一个像素点的投影光线。这种方法适用于大部分的相机，但是没有提出对于图像畸变的闭环解决方案。C. Mei^[11]等人提出了一种方法，该方法统一了相机投影的模型用来标定鱼眼相机和球面相机等。C. Mei 提出的方法和 D. Scaramuzza 的方法类似，只是将光线参数化了而不是使用多项式拟合光线，这样使得标定畸变参数更简单。

对于相机的外参标定，J.-Y. Bouguet 提出的方法可以用来标定具有深度的立体相机。对于两个及两个以上的摄像头，J. Barreto^[12]和 R. Y. Tsai^[13]等人提出的方法可以用来标定外参。但是这些方法针对的相机模型有一个共同特点就是他们都利用相机间的重合视野来标定，也就是说相机的摄像头的朝向都是向内。如果相机的摄像头朝外，或者相机间的共同视野很少就无法完成标定。但是本课题中为了可以充分观测到车辆周围的环境，相机的朝向都是向外。而且，带有向外指向的摄像头应用也越来越广泛。手眼标定的方法可以解决这个问题，如 R. Y. Tsai^[13]和 Y. C. Shiu^[14]等人提出的方法。但是标定过程需要重建每个摄像机的视觉里程计，由于里程计漂移，标定通常都不太准确。

由 Bo Li^[15]等人发明的利用多种尺度的随机噪声图像合成的标定图像可以用来标定摄像头朝外的多相机之间的外参以及相机的内参，但是其中相机间的外参尺度单位是像素，在实际使用中需要从空间单位到像素单位的转换。基于此我们进行了完善用来标定本课题平台中多相机间的参数。



图 1-5 多种相机

1.2.2 单相机和三维激光雷达外参标定研究现状

由于近年来自动驾驶和高级辅助驾驶系统中激光雷达和摄像头的融合对于整个驾驶系统关于周围车辆的识别和感知环境很重要，因此研究三维激光雷达和相机之间的转换关系标定准确性就显得很重要。通常激光雷达和相机标定分为在线

标定^[16, 17]和离线标定，所谓在线标定是通过无人车在行驶过程中通过点云的识别和相机图像识别的方法进行标定，但是在线标定也需要离线标定提供较好的初始值，本课题更关注于离线标定。常用的离线标定方法有三种：棋盘格标定法；特殊几何形状标定法；以及角点检测标定法。Yecheng Lyu 等人^[18]提出了使用比普通木板更硬的玻璃标定板，通过 RANSAC 算法利用打在标定板边缘的点云拟合出标定板边缘直线的方程，通过多条直线分别计算出标定平面的顶点的位置，从而计算出标定板的平面方程。该方法利用的是点云的边缘点，虽然使用了更硬的玻璃标定板相比于木板在空间中不易变形，但是因为点云的稀疏性，在标定板边缘的数据噪声很大，所以拟合出的结果误差较大。Vasconcelos F 等人^[19]提出了一种棋盘格和单线激光雷达的方法，虽然和多线激光雷达有差别并且计算量较大，但是在方法上给我们一定的启发，该方法对于棋盘格的检测的初始解更精确。Pless R 等人^[20]提出了一种通过利用张正友教授提出的利用棋盘格在相机坐标系中的外参进行标定的方法，该方法简单易操作，但是无法计算出完整的旋转矩阵。Park S U 等人^[21]在 Pless R 的基础上进行了优化和扩展，使其可以用来标定多线激光雷达和相机。但是并没有对得到的结果优化。Unnikrishnan R 等人^[22]提出了一种根据两个平面的单应性来求取激光雷达和相机之间的单应矩阵，再根据单应矩阵的性质，分解出旋转矩阵和平移矩阵。但该论文中推导求解的过程不清楚，也未分析外参精度等。在国内韩正勇等人^[23]提出使用将相机坐标系和激光雷达坐标系之间的转换关系分解成旋转和平移两个部分，但是在平移的计算上该论文的精度较低。

目前对于多相机和激光雷达的联合标定还没有找到详细描述解决方案的论文，在 Akshay Rangesh 等人^[24]的论文中概略的描述了他们进行了多相机和激光雷达的标定，但是没有说明具体的解决和实验步骤，我们基于以上的论文加之我们的理解将课题完成。




图 1-6 激光雷达和相机相对位置

1.3 本文主要研究内容及章节安排

1.3.1 研究内容

多相机和激光雷达间的外参组合标定根据实验平台的特点主要有几个问题：激光雷达和相机之间如何确定外参；相机和相机之间的外参如何进行标定；最后如何将整个平台的关系联系起来。

针对这些问题我们提出了两个方案：一个方案是通过每个相机和激光雷达标定一次，这样以激光雷达为坐标中心，将多相机通过激光雷达串联起来；另一个方案是将相机之间的装换关系标定出来，再将一个相机和激光雷达之间的关系标定出来，再通过该相机建立起激光雷达和所有相机之间的关系。对比两种方案并综合调研时的论文可以知道在相机和激光雷达之间的外参标定过程中由于每帧点云中大概会有 60,000 个点，在如此多的点云中识别打在标定板上的点是一件比较麻烦的事情，目前可以使用深度学习来识别点云中的平面，但是深度学习需要很多的参考数据的训练才能得到较好的结果。如果因为标定制造大量的带标签的数据有些得不偿失。因此最简单直接的方法就是人工选择点云。为了使标定的结果比较准确，在进行相机和激光雷达标定时，每次会选几十个位姿的数据。因此，如果使用第一种方案我们的工作量会大大增加。我们最后决定使用第二种方案。

使用第二种方案将研究分解为三个步骤：首先相机和相机之间的转换关系以及每个相机的内参系数的计算；单相机和激光雷达之间的外部转换关系的确定；最后将传感器间的外参串联。在多相机标定中常用的棋盘格标定板由于每个角点的描述子是一样，并且使用棋盘格标定需要拍摄到全部棋盘格，不满足我们实验

平台要求。因此，参考 Bo Li 等人使用随机噪声标定板进行标定。我们的标定方法是离线标定，因此考虑到数据的采集和时间同步，我们使用开源的 ROS 系统进行传感器的数据采集和时间同步。由于五个相机采集到的图片量很大，我们需要将采集到的数据规范命名，并筛选出清晰的标定板图片。接着使用 SURF 方法检测图片的特征点，然后通过匹配特征点并计算出标定板的位姿。接着使用图优化利用拍摄到的同一时刻的标定板位姿将所有相机将的位姿联系起来，最后使用最小化重投影误差的方法完成多相机的外部转换关系和内部参数的标定。

在相机和激光雷达的标定过程中，为了方便在点云中找到打在标定板上的点云以及后面的外参优化，我们设计了一个软件。首先使用 ROS 系统中的工具将采集的信息播放，接着在软件中我们会看到同步播放的图片和点云数据，我们提取标定板的各个位姿数据。在各个位姿的点云中选择打在标定板上的点云，通过所选的点云数据计算出激光雷达坐标系中的标定板位姿及平面法向量，接着使用张正友教授的方法计算出相机坐标系中木板的位姿。设标定板和世界坐标系对齐。接着通过法向量之间的转换关系，以及法向量转换关系和平面转换之间转换关系的联系，计算出相机和激光雷达之间的外参。最后通过最小化点到平面的关系优化外参。

将相机和激光雷达，相机和相机之间的转换关系联立起来完成整个实验平台的标定。

1.3.2 章节安排

本论文的章节安排如下：

第一章阐述了课题的研究背景和意义，描述了多相机之间的外参标定的研究现状，激光雷达和相机之间的外参标定的研究现状，阐述了本课题的主要研究方向和确定方案的过程。

第二章主要阐述了用于离线标定的数据采集，时间同步和数据筛选的过程。同时简介了实验平台的搭建和三维建模的过程中的考量。以及标定图像的选择和生成的过程。

第三章主要阐述了单相机的内参标定以及标定板在每个相机坐标系中位姿，以及相机之间的外参的标定和优化方法。对比了几种特征检测方法及其在标定中

的应用。阐述了标定中的两个平面间的单应性，以及推导了单应性矩阵分解成旋转矩阵和平移矩阵的过程。也阐述了图优化和最小重投影误差的应用。

第四章主要阐述了激光雷达和相机之间的外参标定的流程以及标定软件的使用说明，并阐述了最后将多个传感器串联起来的结果。其中说明了如何在点云中计算出标定板的平面方程，以及标定板在相机视野中的位姿是如何求取。总结了最终的标定结果。

第2章 多相机与激光雷达标定数据采集

2.1 引言

在进行标定之前，首先要采集标定所需要的数据，包括相机拍摄的标定板图像数据和激光雷达检测的点云数据。本章将阐述用于多相机平台标定的标定图像的选择和生成以及单相机与激光雷达标定的标定板图像的选择；多相机和激光雷达感知平台的机械的结构；标定所需要数据的采集和同步。

2.2 多相机和激光雷达平台简介

多相机和激光雷达平台的目的是对自动驾驶车辆周围环境进行 360° 的感知，可用于自动驾驶中构建高清的有颜色的点云地图，也可以为感知和决策提供丰富的色彩信息和精确的点云信息^[25]。基于以上目的，如图 2-1 本课题设计了一种铝合金支架，该支架的机械结构可以稳定固定和支撑五个 Point Grey 相机和一个 32 线激光雷达的。该支架的底座在不改变结构强度的前提下在底座上机械加工了两个减重槽，较轻的机械结构方便装配和搬运也不对车顶增加过多的压力。由于传感器较多导致线缆很多，我们选择在支撑平台上开一个圆孔，这样方便线缆的整理，也不会影响传感器工作。




图 2-1 多相机和激光雷达感知平台

在多相机平台的设计上，我们选择使用五个相同的工业级 Point Grey 相机组成多相机平台。相比于普通的相机，本课题选择的 Point Grey 相机结构更紧凑，所占的空间更小，重量更轻。由于自动驾驶的工作环境大部分时间是在室外，相比于

普通相机工业级的 Point Grey 相机的性能更稳定, 连续工作的时间更长, 产生的噪点更少, 即使环境恶劣也可以稳定的工作。并且我们所选的相机每秒可以轻松拍摄到 200 帧的图像, 这样保证在自动驾驶的过程中尽可能快的感知周围环境的变化。

Point Grey 相机也是很多自动驾驶感知模块选择使用的相机。本课题选择的每个 Point Grey 相机的水平视角为 80° 左右, 在五个相机的均匀环形排布的情况下保证了多相机平台可以对周围环境完整的观测。由于平台是安装在车辆的顶部, 高度较高。而相机的垂直视角是有限的, 如果相机所处的高度较高, 虽然拍摄的视野

会更好, 拍摄的更远。但是相机在拍摄远距离的图像会不清晰同时视野上方比如天空、高楼等远处的信息在自动驾驶中是无用的信息, 所以在固定相机时将平台向下倾斜了 15° , 这样可以使相机更多的拍摄到近距离的有效信息。



图 2-2 工业相机和镜头

在多相机平台的中心装配了一个支架用于固定激光雷达。本课题选用的激光雷达是 ROBOSENSE 公司生产的 RS-LIDAR-32^[26]。该激光雷达是 32 线机械式激光雷达, 垂直测角为 40° , 为了减少探测盲区, 该激光雷达水平线以下的垂直视场角达到 25° , 探测的更充分; 并且 RS-LIDAR-32 激光雷达采用了中间稠密, 两边稀疏的激光头排列方案, 更加关注于激光雷达前方区域的数据采集, 正前方 20 根垂直角分辨率为 0.33° 的激光束, 使得该激光雷达获取前方数据能力大于等于 64 线产品; 精度为 $\pm 5\text{cm}$ (典型值), 测量距离为 $0.2\text{m}\sim 200\text{m}$ (目标反射率 20%), 水平视场角为 360° , 采集的数据类型为三维空间坐标和反射率, 激光雷达的机械旋转频率为 10HZ。可用应用的领域如自动驾驶、高精度地图构建、机器人等领域。和同级别的进口激光雷达相比该型号的产品性价比较高, 因此本课题选用

RS-LIDAR-32 作为点云检测的激光雷达。

2.3 标定图像的选择和生成

2.3.1 图像的特征点检测

无论是相机的内参标定、相机间外参标定、相机和激光雷达之间的外参标定在离线标定中通常都采用这样一种做法：在图像中选择一些比较特殊的点。这些点在相机视角中发生旋转、平移，或者到相机的距离发生变化后保持不变，我们会在不同图像中寻找这样的点，然后在这些点的基础上计算相机的内参和外参。我们称这样的点为特征点。

常用的著名的特征点检测的方法有 SIFT^[27]、SURF^[28]、FAST、ORB^[29]等等。这些人工设计的特征点有如下性质：相同的部分可以在不同图像中找到；不同部分区域有不同的描述；同一图片中，特征点的数量相比于像素的数量小很多；特征点仅与图像中一小片区域有关。通常特征点由关键点（Key-point）和描述子（Descriptor）两部分组成。关键点就是特征点在图像矩阵中的位置，有些特征点还有大小和方向等信息。描述子就是描述关键点附近区域像素的信息，是人为设计出来的，设计原则是按照“外观相似的特征应该有相似的描述子”。因此，当两个特征点的描述子的距离小于设定的范围，就可以认为匹配到的结果是正确的。

但是不同的方法有不同的特点。FAST 提取关键点特别快，但是没有描述子，无法用于标定。ORB 是 FAST 的改进型，在 FAST 的基础上增加了速度极快的二进制描述子 BRIEF，在匹配特征点时只需比较二进制中不同位数的个数就可以快速的匹配到特征点，目前在视觉 SLAM 中很多使用 ORB 算法，在可以较好的提取特征点的前提下还能满足实时性。但是相对照 SIFT 方法，ORB 提取的关键点不如该方法多。而 SURF 算法是在 SIFT 算法的基础上优化提取关键点消耗时间长的问題。虽然 SIFT 算法和 SURF 算法在提取特征时花费的时间比较多，但是考虑到本课题中主要讨论的问题是标定，不要求实时性，所以本课题主要讨论 SIFT 算法和 SURF 算法。

2.3.2 SIFT 算法和 SURF 算法

SIFT 的全称是 Scale Invariant Feature Transform，尺度不变特征转换，由加拿大教授 David G. Lowe 在 1999 年发表，2004 年完善总结。SIFT 通过对图像进行降

采样，将图像分成若干层，构成尺度空间金字塔。在二维空间的高斯模糊公式为

$$G(u, v) = \frac{1}{2\pi\sigma^2} e^{-\frac{(u^2+v^2)}{2\sigma^2}} \quad (2-1)$$

将图像分层后，在每层中对图像进行不同 σ 的高斯卷积， σ 为高斯正态分布的标准差， σ 越大模糊程度越大。空间金字塔中每层被不同 σ 的高斯模糊后的图像组成一组，将每组中相邻的两张图像做差，构成高斯差分金字塔，做差的过程被称为高斯差分用来替代高斯微分函数。

空间极值点检测。在上一步我们构建的差分金字塔上的每组里查找极值，该极值需要对比每组中上一层和下一层同一坐标及周围八个点以及本身坐标周围八个点共 26 点，确保在不同尺度中都为极值点。该过程是在离散的空间中查找极值点，是使用子像素插值法确定极值点的精确位置。再以关键点为中心，以 $3 \times 1.5\sigma_{oct}$ 为半径区域内通过公式

$$\begin{aligned} m(x, y) &= \sqrt{[L(x+1, y) - L(x-1, y)]^2 + [L(x, y+1) - L(x, y-1)]^2} \\ \theta(x, y) &= \arctan \frac{L(x, y+1) - L(x, y-1)}{L(x+1, y) - L(x-1, y)} \end{aligned} \quad (2-2)$$

计算每个关键梯度的模长及方向，其中 $L(x, y) = G(x, y, \sigma) \times I(x, y)$ ， σ_{oct} 为关键点所在高斯差分金字塔具体层的标准差。

关键点特征描述。以关键点为中心，半径 $radius = \frac{3\sigma_{oct} \times \sqrt{2} \times 5}{2}$ 将周围分为 8×8 个子区域，以关键点梯度方向为正方向建立坐标系，将半径区域内的像素点旋转到新的坐标系中，像素的新坐标为

$$\begin{pmatrix} x' \\ y' \end{pmatrix} = \begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} \quad (2-3)$$

求取每个像素点的梯度幅值与梯度方向，接着使用高斯卷积核对它进行卷积运算。然后以 16 个子区域组成一个新的区域，计算梯度直方图并统计每个方向的个数，形成一个种子点，这样 4 个种子点构成一个特征点的描述子。为了稳健也可以将区域分成 16×16 个子区域，增加种子点的个数。

SURF 算法是在 SIFT 算法的基础上进行修改的。SIFT 算法通过 DOG（高斯差分）构建高斯差分金字塔，SURF 算法是基于 Hessian 矩阵，通过积分图像减少运算时间。在描述子的构建上 SURF 利用小波变换计算关键点附近的信息代替 SIFT 算法中计算附近区域点的方向。SURF 比 SIFT 算法的描述子复杂度减少一半，匹

配速度更快。比较 SURF 和 SIFT 两种算法，SURF 算法的效率更高且检测到的特征点数量相同，因此本课题选择 SURF 算法检测特征点。

2.3.3 多相机平台标定图像生成

本课题使用的多相机平台的标定与多视几何^[30]中提到的多相机标定有一个明显的不同，多视几何中提到的多相机标定方法利用相机的重叠视野，相机的镜头都内指内部，所有的相机需要同时观察到相同的空间点才可以标定。而本课题所搭建的多相机平台上的相机都是朝向外侧，共同视野很小。如果本课题中的多相机平台再减少一台相机，那么相机间将没有共同视野。常用的例如张正友教授的相机标定方法在多相机间外参标定上无法使用。另一方面，常用的棋盘格标定图像，如下图。




图 2-3 棋盘格标定版

虽然在特征点检测上很准确，但是特征点是由关键点和描述子两个部分组成，而棋盘格的特征点都是产生在棋盘格的角点上。因为每个角点周围的像素都是相同的，因此每个角点的描述子都是相同的，所以无法匹配两张图片中棋盘格的特征点，也无法确定检测到的特征点在棋盘格中的位置。在相邻的两个相机的视野很少或者没有的情况下，我们需要一种标定板，在这种标定板上可以检测到大量的特征点，并且这些特征点的描述子应该差距很大很容易区分。基于这些特点参考 Bo Li^[15]等人的工作，本课题在多相机平台的内参和外参标定中选择一种基于 SIFT/SURF 检测特征点的检测机制的多噪声图像合成标定板。在构建高斯差分金字塔的过程中，高斯差分滤波可以在噪声图像中产生高响应的点。然而高响应的噪声图片有一个问题就是容易模糊。对于一张灰度噪声图像，如果相机位于图像很远处，那么拍摄出来的图像就是一张完全灰色的图像，无法分辨出图像中的具体细节。对于这个问题的解决方法是用多尺度的噪声合成图像。具体的标定图像生成过程分成三步，首先生成不同分辨率的噪声图片；然后将它们调整为相同分

分辨率，用来模拟不同尺度的噪声；最后将不同尺度的噪声图片合并到同一张图片中。这个过程可以理解为 SIFT/SURF 检测过程中构建空间尺度金字塔的反向过程。因此，得到的图片中包含大量不同尺度的特征点；这些特征点可以根据图像距离相机的不同分别被检测到。生成标定图像的流程如下：




图 2-4 生成标定图像流程

生成本课题用于多相机平台标定的图像如图 2-5 下方的图像，图 2-5 上方的四张图像是不同频率的噪声图像，相当于不同远近和清晰度图像。




图 2-5 标定图像及不同尺度图像

2.3.4 单相机和激光雷达标定板选择

在单相机和激光雷达的标定中，本课题选择的方法是通过计算相机坐标系和

激光雷达坐标系中标定板所在平面的法向量之间的转换关系以及约束点在同一个平面上进行外参的标定。激光雷达的点云数据中无法识别出打在标定板上的点云，需要手动选择点云数据并计算法线向量。图像主要用来计算相机坐标系中标定板的位置和姿态，通过位位置和姿态计算出平面的法向量。在相机和激光雷达的标定中，为了使在较远距离处的标定也很准确，我们需要将标定板拿到距离相机很远的地方。棋盘格标定板的优点的就是结构简单，角点的检测受标定板距离相机的远近的影响很小。多相机标定中应用的多尺度噪声图像在较远处会模糊。因此在单相机与激光雷达的外参标定中我们选择棋盘格标定板。

2.4 标定数据采集

2.4.1 标定数据采集软件

在标定数据采集中涉及到多个相机的图片和激光雷达点云数据的采集。本课题使用在自动驾驶系统开发中常用的 ROS 系统作为数据采集和离线播放的工具。ROS (Robot Operating System) 是一款机器人开发软件，它能提供类似于操作控制系统的很多服务^[31]。它也提供一些工具和库函数，例如可视化工具 Rviz，仿真工具 Gazebo 等，ROS 还支持多计算机间的分布式计算等功能。总之 ROS 是一个轻便，支持多种编程语言，有良好扩展性的机器人开发软件系统。

表 2-1 ROS 系统中的数据传输和处理主要机制

工具包	作用
Nodes	是一系列运行的程序，一个机器人控制系统通常包含许多 Nodes，比如控制相机的 Node，控制激光雷达的 Node，提供图形化界面的 Node 等等
Master	提供 Node 之间查找、交换消息或调用服务等
Messages	Node 之间是通过 Message 来传递消息，一个 Message 就是一个简单的数据结构，ROS 支持自定义 Message 结构
Topics	Topic 中发布消息。Topic 是一个命名用来描述消息内容。一个 Node 可以同时订阅和发布多个 Topics
Services	请求/回应是通过 services 实现，这种通常是成对出现的，一个请求，一个回应。
Bags	Bags 用来存储和播放 ROS 的消息

在本课题中使用 ROS 系统采集标定数据的 Bag，数据的播放和解压，对数据进行时间同步等操作。

2.4.2 多相机标定数据采集

本课题所使用的多相机的平台是由平台中心的 32 线机械式激光雷达触发拍照。该型激光雷达中的伺服电机以 10HZ 的频率旋转，电机返回转子旋转角度，当电机旋转到相应相机的位置时，该相机曝光拍照。相邻相机的曝光时间会有 0.02s 的时间差，近似认为在这 0.02s 中相邻相机拍摄到的标定板没有运动，近似于静止。

将平台放在平坦位置固定，使用 ROS 系统中的可视化软件 Rviz 同步显示五个相机拍摄到的图像，将事先打印好的标定图像平铺在木板上粘贴好。如下图，对五个相机分别命名。最前方的相机命名为相机 1，然后顺时针依次排序，并贴上纸片标记，防止再次使用时混淆。




图 2-6 相机分布示意图

将标定板移动到相机 1 正前方，调整标定板的位置，使其可以完整的出现在相机 1 的视野中，这时通过 ROS 查看 Topics，可以看到五个相机和激光雷达的 Topic，然后使用 ROS 的 Bag 工具订阅传感器的 Topics 并开始录制数据。从相机 1 前方开始缓慢移动标定板，在每个相机前和相邻相机中间略微停留，保证拍摄到的图像清晰。为了是标定的相机内参更准确，在每个相机前停留，使该相机可以拍摄到完整清晰的图像。如图 2-5 为两个相邻相机同时拍摄到标定板的图像。




图 2-7 相邻相机拍摄图

由于相机比较多，所以在数据传输的过程中需要对图像进行格式压缩，不然会由于传输数据量过大造成传输堵塞并丢失部分数据。

虽然我们近似相邻两个相机拍摄到的标定板是同时完成的，但是在数据采集时我们近似同时拍摄到的数据的时间戳还是有不同的。因此，完成数据的采集之后需要使用 ROS 的时间同步工具对采集的数据进行时间同步，并将压缩的图像数据解压到每个相机的文件夹中。

最后，我们需要对图像进行筛选并规范命名。同步解压得到的图像数据中筛选出相邻相机在同一时间戳拍摄到的标定板信息，其中优先选择标定板位于两相机之间的图像，这样在检测特征点时两个图像都可以检测出相对多的特征点，使得计算得到的两个结果都相对准确。还需要挑选出每个摄像头拍摄到完整清楚的标定图像。对图规范格式命名，格式为“相机-时间戳”，例如相机 1 在时间戳 178 拍摄的图像命名为“0-178”。

2.4.3 单相机和激光雷达标定数据采集

单相机和激光雷达的标定数据需要采集相机 1 和激光雷达的点云数据，本课题中令正前方的相机为相机 1。为了减少不必要的步骤我们将标定纸粘贴到木板的背面，调整棋盘格的位置，确定相机视野的边界使其可以被相机完整拍摄。因为激光雷达是 360° 检测，所以不考虑标定板在点云中的位置，在可视化界面中确定相机视野的左中右、前中后一共九个位置，每个位置将标定板分别放在地面前倾、后倾、左倾、右倾、正面五个姿态，再将标定板举起来重复一遍，一共采集 90 个位姿。




图 2-7 采集标定板位置和姿态

2.5 本章小结

第二章我们描述了我们的多相机和激光雷达感知平台的机械结构是如何设计的，在不改变结构强度的前提的通过机械加工铣出一些减重凹槽使结构更轻。在支撑平台的设计中，为了避免应力集中，在有拐角的地方我们都进行了倒角处理，后续如果量产还可以进行表面处理来增加结构的抗腐蚀性。

为了满足自动驾驶中对周围环境全方位的感知，我们选用了五个 Point Grey 工业级相机和一个 32 线的激光雷达。这一套多传感器的感知平台标定的困难之一就是相机之间共同视野很小，常用的张正友教授的相机标定等方法不适于本平台的标定。因此我们参考 Bo Li 等人的方法，根据本课题的特点，使用一种多尺度随机噪声图像的标定板。这种标定方法可以在标定图像部分被观测到的情况下被定位，并计算出位姿，解决了我们平台中相机间视共同野少的问题。

在数据采集中，我们拿着随机噪声标定板围绕着多相机平台走一圈，由于传感器很多导致数据流量很大，所以在采集时的储存设备应该选择读取速度更快的固态硬盘采集数据，并使用六类网线传输数据。在单相机和激光雷达标定中，我们需要在相机视野中的 9 个点，每个点 10 个位姿采集数据。这是一个很大的工作量，也是我们进行课题研究的其中一个原因。

最后，我们将采集到的数据通过 ROS 系统工具进行数据同步，保证同一时刻

拍摄到的图像通过相同时间戳表达出来，这在后面的相机标定中使用。同步后进行数据的筛选，留下清晰的且标定板位于两个相机中间位置的图像，将图像根据所拍摄的相机号分在不同的文件夹中保存好。

本章主要是前期准备工作，为后续的标定提供有效的数据。

第3章 多相机平台标定

3.1 引言

多相机平台的标定工作主要是对相机的内参数和相机间的外部参数标定。所谓相机的内参就是光线透过摄像头的光心投影到相机的感光元件上，在感光元件上从物理成像坐标系到像素成像坐标系的转换关系。多相机间的外参是相机和相机之间在全局坐标系下的相对位置关系。

3.2 单相机标定

在单相机标定中需要计算出每个相机的内参以及在每个相机坐标系中标定板的位姿。

3.2.1 针孔相机模型




图 3-1 针孔相机模型

如图 3-1 所示，是本课题选用的针孔相机的成像原理图。设相机坐标系为 $O-x-y-z$ ，其中 z 轴指向前， x 轴指向左， y 轴指向下，原点 O 是相机的光心。假设在相机坐标系中有一点 P 的坐标为 (x, y, z) ，点 P 经过光心 O 的投影到物理成像平面上点为 P' ， P' 的坐标为 $(x', y', -f)$ ，其中 f 为相机的焦距。如图 3-1 右边所示，根据三角形相似有

$$\frac{Z}{f} = -\frac{X}{X'} = -\frac{Y}{Y'} \quad (3-1)$$

为了方便表达，我们将成像平移到 z 轴正方向，得到

$$\begin{cases} X' = f \frac{X}{Z} \\ Y' = f \frac{Y}{Z} \end{cases} \quad (3-2)$$

这是在物理空间上的坐标转换，但是我们最终看到的图像是从物理坐标系中投影到像素成像平面上，这需要在像素成像平面上对图像进行采样和量化。为了描述相机上的感光元件将感受到的光线转换成图像中的像素的过程，我们设有一个像素平面固定在物理成像平面上，令像素平面的坐标系为 $o-u-v$ 。我们在物理成像平面上的 P' 点在像素平面的坐标为 $[u, v]^T$ 。

本课题使用的像素坐标系定义方式为：原点 o 位于图像的左上角，水平 u 轴向右， v 轴垂直向下，分别与物理成像平面的 x, y 轴平行。像素坐标系与物理投影平面相差一个比例缩放因子和原点间的偏移。我们设 x 轴到 u 轴间缩放为 α ， y 轴到 v 轴间缩放为 β 。同时，原点平移了 $[c_x, c_y]^T$ 。如此， P' 点由物理成像平面到像素坐标 $o-u-v$ 的关系为

$$\begin{cases} u = \alpha X' + c_x \\ v = \beta Y' + c_y \end{cases} \quad (3-3)$$

代入式(3-2)并把 αf 合并为 f_x ，把 βf 合并为 f_y ，得

$$\begin{cases} u = f_x \frac{X}{Z} + c_x \\ v = f_y \frac{Y}{Z} + c_y \end{cases} \quad (3-4)$$

该式中，我们把中间量组成的系数矩阵称为内参矩阵 $\mathbf{K}$ 。一般情况下，相机的内参在生产装配出厂后就固定不变了。如果厂家不提供参数，而自己确定相机内参矩阵系数的工作就是相机的内参标定。

相对于内参矩阵，还有外参矩阵。在式(3-1)中，我们假设的点 P 是在某个相机坐标系下的点，如果另一个相机也观察到 P 点，那么 P 点在另一个相机坐标系中坐标就会是 (x', y', z') ，不同的相机从不同的方位得到的 P 点的坐标是不同的。我们设 P 点在世界坐标系中的坐标为 P_w ，而相机是在运动的。 P 点则是根据相机目前的位姿变换到相机坐标系下得到的结果。相机的外参就是根据它的旋转矩阵 $\mathbf{R}$ 和平移向量 $\mathbf{t}$ 确定的，写成数学表达式为

$$ZP_{uv} = Z \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = K(RP_w + t) = KTP_w \quad (3-5)$$

其中 P_{uv} 是 P 点在像素坐标系下的投影映射坐标，式(3-5)表达的是从世界坐标系下变换到像素坐标系中的过程。

3.2.2 相机畸变模型

为了使成像效果更好，我们通常会在相机的前方加上镜头。但是镜头中的透镜会对光线的传播产生影响：一是镜头会使光线传播发生折射影响，二是在机械装配过程中，镜头中的透镜和感光元件不可能是完全平行的，因此会导致光线透过透镜照在感光元件上时位置发生变化。

因为镜头所使用透镜在不同区域产生不同的折射率所引起的图像畸变称之为径向畸变。在针孔相机模型中，光线通过光心照射到像素成像平面上还是直线。但是，当我们在相机上加上镜头后，相机拍摄出来的图像中直线会发生畸变成曲线，并且越靠近图像的边缘，畸变越严重。径向畸变主要分为两类：桶形畸变和枕形畸变，如图 3-6 所示^[32]。

除了因为所使用的透镜形状导致图像径向畸变外，在镜头的装配过程中由于装配误差导致的透镜和感光元件不平行也会引入切向畸变。

为了更精确的描述图像畸变，使用数学语言对其表达。设平面上一点 a 在笛卡尔坐标系中为 $[x, y]^T$ ，写成极坐标为 $[r, \theta]^T$ ，其中 r 为 a 点到坐标原点的距离， θ 表示射线 $\vec{oa}$ 与水平轴的夹角。径向畸变可以认为是点 a 沿着长度方向的畸变 δr ，也就是点 a 距离原点的距离产生了畸变；同理，切向畸变就是点 a 沿着切线方向畸变，也就水平夹角发生了畸变 $\delta \theta$ 。




图 3-2 相机畸变模型图

对于径向畸变我们可以用 r 的二次或者多次函数纠正

$$\begin{aligned} x_{\text{corrected}} &= x(1 + k_1 r^2 + k_2 r^4 + k_3 r^6) \\ y_{\text{corrected}} &= y(1 + k_1 r^2 + k_2 r^4 + k_3 r^6) \end{aligned} \quad (3-6)$$

对于切向畸变，可以用其他两个参数 p_1 , p_2 来纠正

$$\begin{aligned} x_{\text{corrected}} &= x + 2p_1 xy + p_2(r^2 + 2x^2) \\ y_{\text{corrected}} &= y + p_1(r^2 + 2y^2) + 2p_2 xy \end{aligned} \quad (3-7)$$

将径向畸变纠正函数和切向畸变纠正函数联立，对于相机坐标系中的一点 $A[X, Y, Z]$ ，可以通过几个畸变系数将畸变的点纠正到正确的位置：

1. 将三维空间的点投影到归一化平面上。令其坐标为 $[x, y]^T$ 。
2. 通过矫正函数将矫正光线沿着径向发生的畸变和沿着切向发生的畸变。

$$\begin{cases} x_{\text{corrected}} = x(1 + k_1 r^2 + k_2 r^4 + k_3 r^6) + 2p_1 xy + p_2(r^2 + 2x^2) \\ y_{\text{corrected}} = y(1 + k_1 r^2 + k_2 r^4 + k_3 r^6) + p_1(r^2 + 2y^2) + 2p_2 xy \end{cases} \quad (3-8)$$

3. 将矫正后归一化平面上的点映射到像素坐标系。

$$\begin{cases} u = f_x x_{\text{corrected}} + c_x \\ v = f_y y_{\text{corrected}} + c_y \end{cases} \quad (3-9)$$

由于我们使用的 Point Grey 相机径向畸变和切向畸变不是很严重，只使用 k_1, p_1, p_2 这三项就足以描述径向和切向畸变，因此本课题使用的畸变纠正公式为

$$\begin{cases} x_{\text{corrected}} = x(1 + k_1 r^2 + k_2 r^4) + 2p_1 xy + p_2(r^2 + 2x^2) \\ y_{\text{corrected}} = y(1 + k_1 r^2 + k_2 r^4) + p_1(r^2 + 2y^2) + 2p_2 xy \end{cases} \quad (3-10)$$

3.2.3 单相机标定

在单相机标定中，首先要将全局坐标系中的三维空间点与二维图像坐标系中的像素点对应上。这一过程是通过第二章中的 SURF 特征点检测以及特征点的匹配过程完成的。

如图 3-3 所示是标定板特征点和标定使用的图像特征点的匹配过程，左侧为标定板，右侧为标定使用的图像。首先计算标定板的关键点和描述子，用绿色圆圈表示关键点的位置，接着计算标定使用的图像的关键点和描述子用红色圆圈表示。为了使匹配到的特征点更多更稳健，在计算相机拍摄到的原图的同时也会对图像进行直方图均衡化，增加对比度。直方图均衡化的基本思想是：原始的灰度图像由于灰度集中在一个区域内，导致图像的对比度很小，图像不清晰。而直方图均衡化要做的就是将最开始的图像直方图分布映射到另一个灰度直方图分布更宽的图像中，增加对比度使图片更清晰。在将图像均衡化之后，同样检测变换后的图像的关键点和描述子。匹配原图和变换后的图像同标定使用的图像的描述子，统计比较哪张图像匹配到的描述子更多，使用该张图像作为标定图像。因为匹配到的描述子说明图像可提供的信息越丰富，在后面的优化中得到的结果更精确。




图 3-3 匹配特征点

设标定图像上的点的坐标为 $[x, y, z]^T$ ，由于点是在标定平面上，所以令标定图像上的点的坐标为 $[x, y, 0]^T$ 。由全局坐标系变换到相机物理成像坐标系是由相机的外参变换得到，如式(3-11)所示

$$\mu \begin{bmatrix} u \\ v \\ f(u,v) \end{bmatrix} = \mathbf{K} \begin{bmatrix} \mathbf{r}_1 & \mathbf{r}_2 & \mathbf{r}_3 & \mathbf{t} \end{bmatrix} \begin{bmatrix} x \\ y \\ 0 \\ 1 \end{bmatrix} = \mathbf{K} \begin{bmatrix} \mathbf{r}_1 & \mathbf{r}_2 & \mathbf{t} \end{bmatrix} \mathbf{p}^c \quad (3-11)$$

其中 $f(u,v)$ 为相机的焦距，设水平焦距为 α ，垂直焦距为 β ， $\mathbf{p}^c$ 标定图像上的点。 $\mathbf{K}$ 为相机的内参，用来描述物理成像坐标系到像素成像坐标系间的映射，写成线性矩阵形式为

$$\mathbf{K} = \begin{bmatrix} \alpha & \gamma & c_x \\ 0 & \beta & c_y \\ 0 & 0 & 1 \end{bmatrix} \quad (3-12)$$

其中 c_x 和 c_y 是物理成像坐标系相对于像素坐标系的原点间的位移，本课题中 c_x 和 c_y 等于相机拍摄图片的长和宽的一半。认为像素坐标系中横纵坐标轴是垂直的，所以初始化 $\gamma = 0$ 。

现在，我们阐述在标定中使用的一种转换矩阵，通常称之为单应矩阵 $\mathbf{H}$ [33]，单应矩阵描述的是两个平面在空间中的映射关系。如果相机视野中的特征点都落在同一个平面上（例如我们使用相机拍摄到的标定板图像等），就可以利用单应性进行外参估计或者计算两帧图像间的运动。

单应矩阵计算中所使用的点都是位于同一个平面上的点。我们假设在图像 $\mathbf{M}_1$ 和 $\mathbf{M}_2$ 之间已经有一对匹配好的特征点 $\mathbf{a}_1$ 和 $\mathbf{a}_2$ 。这些特征点都在标定板上（假设标定板足够平）。设标定板满足平面方程

$$\mathbf{n}^T \mathbf{P} + \mathbf{d} = 0 \quad (3-13)$$

整理得

$$-\frac{\mathbf{n}^T \mathbf{P}}{\mathbf{d}} = 1 \quad (3-14)$$

根据公式(3-11)，得

$$\begin{aligned} \mathbf{a}_2 &= \mathbf{K}(\mathbf{R}\mathbf{P} + \mathbf{t}) \\ &= \mathbf{K}(\mathbf{R}\mathbf{P} + \mathbf{t} \cdot (-\frac{\mathbf{n}^T \mathbf{P}}{\mathbf{d}})) \\ &= \mathbf{K}(\mathbf{R} - \frac{\mathbf{t}\mathbf{n}^T}{\mathbf{d}})\mathbf{P} \\ &= \mathbf{K}(\mathbf{R} - \frac{\mathbf{t}\mathbf{n}^T}{\mathbf{d}})\mathbf{K}^{-1}\mathbf{a}_1 \end{aligned} \quad (3-15)$$

于是，我们得到了转换关系，这个转换关系描述从一个图像坐标直接转换到

另一个图像坐标的过程，我们把这个转换关系矩阵记为 $\mathbf{H}$ ，代入可得

$$\mathbf{a}_2 = \mathbf{H}\mathbf{a}_1 \quad (3-16)$$

$\mathbf{H}$ 是一个 3×3 的矩阵，矩阵的定义与旋转、平移以及平面的参数有关^[34]。该矩阵有 8 个自由度，所以待求的未知变量有 8 个。设 $\mathbf{a}_1$ 点的坐标为 $[x, y, 1]^T$ ， $\mathbf{a}_2$ 的

$$\begin{aligned} \text{坐标为 } [u, v, 1]^T, \quad \mathbf{H} = \begin{bmatrix} h_1 & h_2 & h_3 \\ h_4 & h_5 & h_6 \\ h_7 & h_8 & h_9 \end{bmatrix} \text{ 代入方程写成齐次方程形式可得} \\ \begin{cases} -h_1x - h_2y - h_3 + (h_7x + h_8y + h_9)u = 0 \\ -h_4x - h_5y - h_6 + (h_7x + h_8y + h_9)v = 0 \end{cases} \end{aligned} \quad (3-17)$$

写成线性矩阵形式 $\mathbf{A}\mathbf{h} = 0$

$$\mathbf{A} = \begin{pmatrix} -x & -y & -1 & 0 & 0 & 0 & ux & uy & u \\ 0 & 0 & 0 & -x & -y & -1 & vx & vy & v \end{pmatrix} \quad (3-18)$$

$$\mathbf{h} = (h_1 \ h_2 \ h_3 \ h_4 \ h_5 \ h_6 \ h_7 \ h_8 \ h_9)^T \quad (3-19)$$

根据 $\mathbf{h}$ 矩阵的自由度为 8，可知至少需要 8 组方程可解出未知参数，而每对匹配点可以提供两组方程，一次最少需要 4 对匹配好的点才能保证计算出方程。通常情况下为了使解出的参数更稳健，我们会使用多于 4 对的匹配点，对于 n 个匹配到的特征点可以写成

$$\begin{pmatrix} -x_1 & -y_1 & -1 & 0 & 0 & 0 & u_1x_1 & u_1y_1 & u_1 \\ 0 & 0 & 0 & -x_1 & -y_1 & -1 & v_1x_1 & v_1y_1 & v_1 \\ & & & \vdots & \vdots & \vdots & & & \\ -x_n & -y_n & -1 & 0 & 0 & 0 & u_nx_n & u_ny_n & u_n \\ 0 & 0 & 0 & -x_n & -y_n & -1 & v_nx_n & v_ny_n & v_n \end{pmatrix} \mathbf{h} = 0 \quad (3-20)$$

但是这样会使方程变成一个超定方程，也就是约束太多，未知数无法满足每一个约束。通常可以使用最小二乘求解出最终的结果，求解最小二乘方程可以通过对系数矩阵进行 SVD 分解（奇异值分解）系数矩阵中最小的奇异值对应的奇异向量就是方程组的解^[35]。其证明如下

解方程 $\mathbf{A}\mathbf{h} = 0$ 等价于优化问题

$$\begin{aligned} \min \|\mathbf{A}\mathbf{h}\| \\ \text{s.t. } \|\mathbf{h}\| = 1 \end{aligned} \quad (3-21)$$

因为 $\mathbf{U}$ 是单位正交矩阵，所以 $\|\mathbf{A}\mathbf{h}\| = \|\mathbf{U}\Sigma\mathbf{V}^T\mathbf{h}\| = \|\Sigma\mathbf{V}^T\mathbf{h}\|$ 。令 $\mathbf{y} = \mathbf{V}^T\mathbf{h}$ ，则方程等价于

$$\begin{aligned} \min & \|\Sigma \mathbf{y}\| \\ \text{s.t.} & \|\mathbf{y}\| = 1 \end{aligned} \quad (3-22)$$

由于 Σ 是一个只有对角线上有元素的矩阵，接着将矩阵的元素按由大到小排序。因此所求的解在 $\mathbf{y} = (0, 0, \dots, 1)^T$ 取得，就是在矩阵 Σ 中的最小的奇异值对应的矩阵 $\mathbf{V}$ 中的奇异向量。因此，单应矩阵的解就是对矩阵 $\mathbf{A}$ 的 SVD 分解 $\mathbf{A} = \mathbf{U}\Sigma\mathbf{V}^T$ 中 $\mathbf{V}$ 的最后一列。这样结算得到的 H 与真实解相差一个常数因子，即

$$\mathbf{H} = (\mathbf{h}_1 \quad \mathbf{h}_2 \quad \mathbf{h}_3) = \lambda \mathbf{K} (\mathbf{r}_1 \quad \mathbf{r}_2 \quad \mathbf{t}) \quad (3-23)$$

整理得

$$\begin{cases} \mathbf{r}_1 = \frac{1}{\lambda} \mathbf{K}^{-1} \mathbf{h}_1 \\ \mathbf{r}_2 = \frac{1}{\lambda} \mathbf{K}^{-1} \mathbf{h}_2 \end{cases} \quad (3-24)$$

旋转矩阵是一个酉矩阵，旋转向量 $\mathbf{r}_1$ 和旋转向量 $\mathbf{r}_2$ 正交且模长为 1，即

$$\begin{cases} \mathbf{r}_1^T \mathbf{r}_2 = 0 \\ \|\mathbf{r}_1\| = \|\mathbf{r}_2\| = 1 \end{cases} \quad (3-25)$$

将式(3-24)代入可得约束

$$\begin{cases} \mathbf{h}_1^T \mathbf{K}^{-T} \mathbf{K}^{-1} \mathbf{h}_2 = 0 \\ \mathbf{h}_1^T \mathbf{K}^{-T} \mathbf{K}^{-1} \mathbf{h}_1 = \mathbf{h}_1^T \mathbf{K}^{-T} \mathbf{K}^{-1} \mathbf{h}_2 \end{cases} \quad (3-26)$$

从式(3-26)中能够看出一个单应矩阵能够提供两个等式，内参矩阵中有 5 个参数，要想求解内参矩阵须有 3 个及 3 个以上的线性无关的单应矩阵。为了得到非线性相关的单应矩阵，需要多个不同的标定板位姿，我们通过选择多张被两个相机同时拍摄到的标定板图像用来标定。我们设内参矩阵为

$$\mathbf{K} = \begin{bmatrix} \alpha & \gamma & c_x \\ 0 & \beta & c_y \\ 0 & 0 & 1 \end{bmatrix} \quad (3-27)$$

设矩阵 $\mathbf{B} = \mathbf{K}^{-T} \mathbf{K}^{-1}$ ，则 $\mathbf{B}$ 矩阵可以表示为

$$\mathbf{B} = \begin{pmatrix} B_{11} & B_{12} & B_{13} \\ B_{21} & B_{22} & B_{23} \\ B_{31} & B_{32} & B_{33} \end{pmatrix} = \begin{pmatrix} \frac{1}{\alpha^2} & 0 & -\frac{u_0}{\alpha^2} \\ 0 & \frac{1}{\beta^2} & -\frac{v_0}{\beta^2} \\ -\frac{u_0}{\alpha^2} & -\frac{v_0}{\beta^2} & \frac{u_0^2}{\alpha^2} + \frac{v_0^2}{\beta^2} + 1 \end{pmatrix} \quad (3-28)$$

可以看出 $\mathbf{B}$ 矩阵是一个对称矩阵，所以 $\mathbf{B}$ 的有效元素为五个，将这五个写成向量形式为

$$\mathbf{b} = (B_{11} \ B_{22} \ B_{13} \ B_{23} \ B_{33}) \quad (3-29)$$

联立式(3-26)中的一式可得

$$\mathbf{h}_i^T \mathbf{B} \mathbf{h}_j = \mathbf{v}_{ij}^T \mathbf{b} \quad (3-30)$$

其中 $\mathbf{v}_{ij} = (h_{i1}h_{j1} \ h_{i2}h_{j2} \ h_{i3}h_{j1} + h_{i1}h_{j3} \ h_{i3}h_{j2} + h_{i2}h_{j3} \ h_{i3}h_{j3})^T$ ，利用式(3-26)可得

$$\begin{pmatrix} \mathbf{v}_{12}^T \\ (\mathbf{v}_{11} - \mathbf{v}_{22})^T \end{pmatrix} \mathbf{b} = 0 \quad (3-31)$$

通过代入单应性矩阵求解出矩阵 $\mathbf{B}$ ，接着通过楚列斯基分解，也就是将一个正定的埃米特矩阵分解成下三角矩阵和下三角矩阵的共轭转置的乘积，然后得到相机的内参矩阵 $\mathbf{K}$ 的水平焦距 α 和垂直焦距 β 。为了方便表达，我们定义一个参数 c

$$c = B_{33} - \frac{B_{13}^2 + v_0(B_{12}B_{13} - B_{11}B_{23})}{B_{11}} \quad (3-32)$$

$$\begin{aligned} \alpha &= \sqrt{\frac{c}{B_{11}}} \\ \beta &= \sqrt{\frac{cB_{11}}{B_{11}B_{22} - B_{12}^2}} \end{aligned} \quad (3-33)$$

其中 v_0 为图像垂直分辨率的一半， u_0 为图像水平分辨率的一半。根据式(3-33)的二式可得尺度参数为

$$\lambda = \frac{1}{\|\mathbf{K}^{-1}\mathbf{h}_1\|} = \frac{1}{\|\mathbf{K}^{-1}\mathbf{h}_2\|} \quad (3-34)$$

将式(3-34)的尺度参数代入式(3-24)中可得求得旋转向量 $\mathbf{r}_1$ 和 $\mathbf{r}_2$ 。根据旋转向量的性质：模长为 1 且互相垂直可，可求得 $\mathbf{r}_3 = \mathbf{r}_1 \times \mathbf{r}_2$ 。将单应性矩阵向量 $\mathbf{h}_3$ 代入式(3-24)可得平移向量 $\mathbf{t} = \lambda \mathbf{K}^{-1} \mathbf{h}_3$ 。

接着进行畸变系数的估计及内参和外参的优化。畸变估计我们参考张正友教授的畸变参数估计，在张正友教授的论文中只考虑切向畸变，也就是式(3-10)中的 p_1 和 p_2 为零。接着根据式(3-10)可以将物理成像坐标系转换到像素坐标系下，其畸变表达式为

$$\begin{cases} \hat{u} = u_0 + \alpha x_{\text{corrected}} \\ \hat{v} = v_0 + \beta y_{\text{corrected}} \end{cases} \quad (3-35)$$

整理代入可得

$$\begin{cases} \hat{u} = u + (u - u_0)[k_1 r^2 + k_2 r^4] \\ \hat{v} = v + (v - v_0)[k_1 r^2 + k_2 r^4] \end{cases} \quad (3-36)$$

写成线性等式形式为

$$\begin{pmatrix} (u - u_0)r^2 & (u - u_0)r^4 \\ (v - v_0)r^2 & (v - v_0)r^4 \end{pmatrix} \begin{pmatrix} k_1 \\ k_2 \end{pmatrix} = \begin{pmatrix} \hat{u} - u \\ \hat{v} - v \end{pmatrix} \quad (3-37)$$

简写成 $\mathbf{D}\mathbf{k} = \mathbf{d}$, $\mathbf{k} = [k_1 \ k_2]^T = (\mathbf{D}^T \mathbf{D})^{-1} \mathbf{D}^T \mathbf{d}$ 。这一推导过程是理想情况下的, 由于在拍照过程中会有噪声出现, 使结果产生一定偏差, 假设拍照中图像的噪声为高斯白噪声, 使用概率方法对其进行最大似然估计。使用的方法是最小化重投影误差, 也就是 Bundle Adjustment (又译为光束平差、捆集调整等) 下文简称 BA^[36]。

BA 不仅在本课题中应用, 在以图优化为框架的视觉定位与建图的算法中都起到了核心作用。在近几年的定位和建图理论的探索中, BA 算法不仅提供了高精度的优化算法, 同时也具有了实时性。因此学习和研究 BA 算法不仅可以应用在本课题的优化上, 也对日后学习的 SLAM 的后端优化做准备。

结合上文我们简介的 BA 流程。在前文中我们首先输入标定图像和打印出来的标定图像的实际尺寸, 然后计算出标定图像中特征点的空间坐标, 将已知坐标的空间点投影到归一化平面中, 接着对归一化坐标去畸变, 得到去畸变后的坐标, 最后根据内参模型, 计算像素坐标。用数学表达式表达为

$$\mathbf{M} = m(\mathbf{x}, \mathbf{y}) \quad (3-38)$$

我们对式(3-38)详细参数化, 这里 $\mathbf{x}$ 代表的是相机外参, 也就是就是前文计算出的旋转矩阵 $\mathbf{R}$ 和平移矩阵 $\mathbf{t}$, $\mathbf{y}$ 代表空间点的坐标, 我们得到的观测数据是相机拍摄到的图片的特征点的像素坐标 $\mathbf{z} \triangleq [\hat{u}, \hat{v}]^T$ 。从最小二乘的角度考虑, 可以得到一次观测的误差

$$\mathbf{e} = \mathbf{z} - \mathbf{m}(\mathbf{x}, \mathbf{y}) \quad (3-39)$$

然后, 我们把筛选出的照片每一张都作为一次观测, 将所有误差累计在一起构建形成一个最小二乘问题。将每次得到的误差加上下角标, 我们人为规定 z_{ij} 为第 i 张图片的第 j 个特征点的坐标。同样 x_i 为第 i 张图像中标定板的位姿, y_j 为第 j 个特征点的空间坐标, 整理得到具体的代价函数 (Cost Function) 为

$$\frac{1}{2} \sum_{i=1}^a \sum_{j=1}^b \|\mathbf{e}_{ij}\|^2 = \frac{1}{2} \sum_{i=1}^a \sum_{j=1}^b \|\mathbf{z}_{ij} - \mathbf{m}(\mathbf{x}_i, \mathbf{y}_i)\|^2 \quad (3-40)$$

我们的目标就是最小化这个代价函数，接着使用非线性优化来求解出最优的解。由于我们要解出的非线性方程比较复杂，所以直接求解方程的最优解是非常复杂甚至无法得到解析解。因此，我们一般采用迭代的方式，从一个距离最优解较近的初始出发，不断地更新当前的变量，使目标函数逐渐收敛到最优的解。

这让通过求解导数为零来求解极值的问题，变成不断地寻找梯度使用该梯度值使函数不断地下降的过程。直到更新的变量变化很小，函数也稳定在一个值不变了。此时，算法收敛到一个极小值，我们也结束了寻找最小值的过程。

接着研究如何更新内参的参数和寻找梯度下降的方向。一般求解参数增量的最直接的方法就是在目标函数 $f(\mathbf{x})$ 的变量周围进行泰勒展开，我们设目标函数为 $f(\mathbf{x})$

$$\|f(\mathbf{x} + \Delta\mathbf{x})\|_2^2 \approx \|f(\mathbf{x})\|_2^2 + \mathbf{J}(\mathbf{x})\Delta\mathbf{x} + \frac{1}{2} \Delta\mathbf{x}^T \mathbf{H} \Delta\mathbf{x} \quad (3-41)$$

其中 $\mathbf{J}(\mathbf{x})$ 是 $\|f(\mathbf{x})\|_2^2$ 关于 $\mathbf{x}$ 的导数的 Jacobian 矩阵，而 $\mathbf{H}$ 则是关于 $\mathbf{x}$ 的二阶导数的 Hessian 矩阵。当我们选择保留泰勒展开的一阶导数时，那么下降梯度方向可以表示为

$$\Delta\mathbf{x}^* = -\mathbf{J}^T(\mathbf{x}) \quad (3-42)$$

它的直观的意思就是沿着梯度的反方向迭代。然后，在该方向上选择一个步长 λ ，计算出下降最快的向量。这种方法称之为最速下降法。

如果保留二阶导数，那么下降梯度方向可以表示为

$$\Delta\mathbf{x}^* = \arg \min \|f(\mathbf{x})\|_2^2 + \mathbf{J}(\mathbf{x})\Delta\mathbf{x} + \frac{1}{2} \Delta\mathbf{x}^T \mathbf{H} \Delta\mathbf{x} \quad (3-43)$$

求等式右侧关于 $\Delta\mathbf{x}$ 的导数等于零的解，可得 $\Delta\mathbf{x}$ 的解

$$\mathbf{H}\Delta\mathbf{x} = -\mathbf{J}^T(\mathbf{x}) \quad (3-44)$$

这个方法又称为牛顿法，相比较来说一阶和二阶梯度法都比较直接，将函数在想要迭代的点附近使用泰勒公式展开，求取更新量极小值即可。将函数进行泰勒展开之后函数变成多项线性方程，只需要求解这个多项式就可以，避免了直接对复杂的非线性方程求导求极值。但是，一阶梯度法和牛顿法也存在问题，由于这两种方法总是最求最快速的下降梯度，在迭代点和目标点之间容易走出锯齿形状，反而是迭代次数增加，收敛时间增长。同时牛顿法还要求取二阶的海塞矩阵，

有时候问题很复杂，矩阵很大，求取一阶的雅可比矩阵已经很复杂了，要求二阶的海塞矩阵就更复杂了。所以在实际使用时我们会尽量避免求取海塞矩阵。所以我们在高斯牛顿法或者 LM 方法中选择一种。

高斯牛顿法的思想是将 $f(x)$ 进行一阶泰勒展开

$$f(x + \Delta x) \approx f(x) + \mathbf{J}(x)\Delta x \quad (3-45)$$

这里 $\mathbf{J}(x)$ 是 $f(x)$ 关于变量 x 的导数，也是一个雅可比矩阵。根据上文所述，我们要找到一个矢量 Δx ，使得 $\|f(x + \Delta x)\|^2$ 最小。为了计算出 Δx ，下面需要求解一个最小二乘问题

$$\Delta x^* = \arg \min_{\Delta x} \frac{1}{2} \|f(x) + \mathbf{J}(x)\Delta x\|^2 \quad (3-46)$$

根据导数性质，我们将式(3-46)展开，并对 Δx 求导，可得到

$$\begin{aligned} \frac{1}{2} \|f(x) + \mathbf{J}(x)\Delta x\|^2 &= \frac{1}{2} (f(x) + \mathbf{J}(x)\Delta x)^T (f(x) + \mathbf{J}(x)\Delta x) \\ &= \frac{1}{2} (\|f(x)\|_2^2 + 2f(x)^T \mathbf{J}(x)\Delta x + \Delta x^T \mathbf{J}(x)^T \mathbf{J}(x)\Delta x) \end{aligned} \quad (3-47)$$

将式(3-47)对 Δx 的导数为零

$$2\mathbf{J}(x)^T f(x) + 2\mathbf{J}(x)^T \mathbf{J}(x)\Delta x = 0 \quad (3-48)$$

最后可得到关于 Δx 的方程组

$$\mathbf{J}(x)^T \mathbf{J}(x)\Delta x = -\mathbf{J}(x)^T f(x) \quad (3-49)$$

因为我们要求的是 Δx ，所以这是一个线性方程组，我们称之为高斯牛顿方程或者正规方程。将左边的系数矩阵定义为 $\mathbf{H}$ ，右式定义为 $\mathbf{g}$ ，式(3-49)简写为

$$\mathbf{H}\Delta x = \mathbf{g} \quad (3-50)$$

对比上文提到的牛顿法，这里的 $\mathbf{H}$ 不是上文中的海塞矩阵，它的意义是用 $\mathbf{J}(x)^T \mathbf{J}(x)$ 近似牛顿法中海塞矩阵，从而避免了求二次导数，节省计算量。求解增量方程是高斯牛顿方法中最重要的一步，但是在实际计算过程中 $\mathbf{J}(x)^T \mathbf{J}(x)$ 却是半正定的，也就说在实际中 $\mathbf{J}(x)^T \mathbf{J}(x)$ 有可能是奇异矩阵，此时计算的增量有可能是不稳定的，导致计算过程不收敛。另一个缺点是，如果我们计算得到的 Δx 太大，会使式(3-45)的近似结果不够精确，最终会导致迭代不收敛，甚至使目标函数的值向变大的方向发展。我们最后选择了稳定性更好一些的 LM 方法。

在上文中我们知道高斯牛顿法是对目标函数进行泰勒展开然后保留二阶导数项，然后用 $\mathbf{J}(x)^T \mathbf{J}(x)$ 近似为海塞矩阵计算步长 Δx ，但是如果步长 Δx 太大会使近似

不准确。而列文伯格—马夸尔特方法的思想是给 Δx 一个信任区间，如果 Δx 在信任区间内我们认为近似的比较好；如果在信任区间外，我们认为近似的不太好，会限制步长。这里面的主要问题是如何确定信任区域的范围，列文伯格—马夸尔特方法使用的是根据近似模型和实际模型之间的差异来确定信任空间的范围。如果差异较小，那我们就扩大这个范围；如果差异较大，那么我们就缩小这个范围。将差异用比值的形式表示为

$$\rho = \frac{f(x + \Delta x) - f(x)}{\mathbf{J}(x)\Delta x} \quad (3-51)$$

其中分子表示的是实际的目标函数下降的量，分母表示的是我们近似的目标函数下降的量。如果 ρ 接近 1，说明实际下降的量和近似下降的量差异小；如果 ρ 比较小，说明实际下降的量比近似下降的量小很多，近似的效果不好，应该缩小近似范围。反之，如果 ρ 比较大，说明实际下降的量比近似下降的量大很多，说明比我们预期的效果更好，可以放大近似范围。

流程图中优化半径的扩大倍数和 ρ 的阈值都是经验值，列文伯格提出的优化方法中是将增量 Δx 限定在半径为 μ 的球内，也就是 $\mathbf{D}$ 为单位矩阵，认为在球内增量是有效的。马夸尔特提出加入非负数对角矩阵 $\mathbf{D}$ ， $\mathbf{D}$ 中的元素通常是 $\mathbf{J}(x)^T \mathbf{J}(x)$ 对角元素的平方根，将 Δx 限定在了椭球内。为了求解等式(3-52)

$$\min_{\Delta x_k} \frac{1}{2} \|f(x_k) + \mathbf{J}(x_k)\Delta x_k\|^2, \quad \text{s.t.} \|\mathbf{D}\Delta x_k\|^2 \leq \mu \quad (3-52)$$




图 3-4 LM 方法计算流程

这是一个带范围约束的问题，我们用拉格朗日乘子将等式转换成一个无约束优化问题：

$$\min_{\Delta x_k} \frac{1}{2} \|f(x_k) + J(x_k)\Delta x_k\|^2 + \frac{\lambda}{2} \|D\Delta x\|^2 \quad (3-53)$$

类似于高斯--牛顿法的处理过程，将式(3-52)展开，得到

$$(H + \lambda D^T D)\Delta x = g \quad (3-54)$$

可以看出，主要问题还是求取 Δx 的线性方程。相比于高斯--牛顿法，在式(3-54)中多了一项 $\lambda D^T D$ ，使用列文伯格的方法简化(3-54)

$$(H + \lambda I)\Delta x = g \quad (3-55)$$

分析(3-55)可以看出，当 λ 较小时， H 占主导地位，LM 方法更接近于高斯-牛顿法，也就是说二次近似和目标函数的差异较小；当 λ 较大时， λI 占主导地位，此时式(3-55)更像是一阶梯度法，也就是说二次近似和目标函数的差异较大，主要使用一次近似来求解。列文伯格—马夸尔特方法在一定程度上解决了高斯—牛顿方法中线性方程组非奇异问题。

如图 3-5 所示，可以看出在进行重投影误差优化之前，初始化相机的内参和外参再投影过去相机 1 最大会有 12.6947 个像素的偏差，最小会有 5.1701 个像素的偏差；相机 2 最大会有 10.2208 个像素的偏差，最小会有 2.6003 个像素的偏差。在优化后相机 1 的重投影误差均值在 0.55915 个像素，像素 2 的重投影误差在 0.525693 个。可以看出通过最小化重投影误差，可以将投影误差缩小一个数量级，达到我们标定的需求，满足后续的使用要求。

Initialize Camera #1...	Initialize Camera #2...
....Init error for 1 = 8.7432	Init error for 1 = 5.7366
....Init error for 2 = 12.6947	Init error for 2 = 5.8047
....Init error for 3 = 11.6111	Init error for 3 = 10.2208
....Init error for 4 = 10.3176	Init error for 4 = 3.6119
....Init error for 5 = 7.7921	Init error for 5 = 2.6003
....Init error for 6 = 9.4465	Init error for 6 = 9.9639
....Init error for 7 = 10.8208	Init error for 7 = 8.5493
....Init error for 9 = 5.1701	Init error for 8 = 9.9326
....Final error for photo1 = 0.6017	Init error for 9 = 10.0576
....Final error for photo2 = 0.60215	Final error for photo1 = 0.46987
....Final error for photo3 = 0.62677	Final error for photo2 = 0.52102
....Final error for photo4 = 0.59075	Final error for photo3 = 0.49825
....Final error for photo5 = 0.52241	Final error for photo4 = 0.42434
....Final error for photo6 = 0.53806	Final error for photo5 = 0.49328
....Final error for photo7 = 0.42116	Final error for photo6 = 0.51599
....Final error for photo9 = 0.55886	Final error for photo7 = 0.61644
....Optimization result:	Final error for photo8 = 0.54608
.....error = 0.55915	Final error for photo9 = 0.52575
	Optimization result:
	error = 0.52693

图 3-5 重投影误差

3.3 多相机标定

通过上一节的单相机标定我们在标定相机的内参的同时也到了相机的外参，也就是标定板在相机中的位姿。但是，这个位姿是标定板在拍摄到它的相机坐标系下的姿态。我们需要得到的是在全局坐标系下的每个相机的位置和姿态。因此，我们需计算出相机之间的转换关系，最后统一到全局坐标系中。

为了计算出相机之间的转换关系，并且优化这个关系，我们选择了在同时定位与建图中主流的优化方法—图优化（graph-based optimization）。在介绍图优化之前我们首先要了解图。

图形理论（简称图论）^[37]是瑞士数学家欧拉（Euler）为了解决“哥尼斯堡”问题时提出的一种数据结构理论，也就是很出名的“七桥问题”。图是由“顶点”（Vertex）和“边”（Edge）构成的集合，图论就是研究顶点和边之间的关系的理论。通常我们用 $G = \{V, E\}$ 来表示一个图，其中 V 表示图中顶点的集合， E 表示图中边的集合。如图 3-5，中心五个有圆圈的平面为五个相机的位姿示意图，我们将五个相机作为五个顶点，记为 cam_i ；外围的六个平面是我们上一步计算出的标定板在每个相机中位姿也作为顶点，记为 pat_i 。顶点就是一个一个等待连接的点，而连接这些顶点的称为边，边可以分为有向边和无向边。有向边意味着顶点只能顺着边由一头通向另一头，而不能反向连通，有向边对应的图称之为有向图；无向边意味着顶点两头可以通过边随意连通，无向边对应的图称之为无向图。有的边可以只连接一个顶点，称为一元边；有的可以连接两个顶点，称为二元边。如图 3-5 所示，在本课题中，使用相机拍摄到的标定板的图像作为连接相机顶点和标定板位姿顶点的边，每一个图像映射为一个二元边，只连接两个顶点。本课题中构成的图是无向的位姿图，简称位姿图。




图 3-6 相机和标定图像示意图

在位姿图中，我们可以在顶点中保存相机和标定板在世界坐标系中的位姿，边可以用来保存相机位姿顶点和标定板位姿顶点之间的转换关系。对于每一张图片，它是由 cam_i 拍摄到的标定板的位姿 pat_i 。我们已经在单相机标定中计算出了每张图片中标定板在该相机坐标系中的相对位姿。

如图 3-7 所示，就是我们采集的标定数据构建的位姿图。从图中可以观察到有的位姿顶点只和一个相机位姿顶点连接，这样的顶点虽然不会对相机间的外参标定有贡献，但是这样的数据是单个相机拍摄完整标定板的图像，在特征点检测中会检测到更多的特征点在单相机标定中的重投影误差的优化中会有积极的贡献。另一部分顶点连接了两个相机顶点，这样通过拍摄到的一个个图像边就会将五个相机都连接起来。由于我们相机间的重合视野很小，所以不会出现间隔的两个相机相连的情况。




图 3-7 位姿图

在构建位姿图之后我们需要遍历位姿图。常用遍历图的方法有深度优先和广度优先^[38]。深度优先遍历方法是结合了递归和堆栈这两种方法的特点，堆栈的特点就是类似一个装乒乓球的圆筒，这个圆筒只有一个开口，先得数据会被压在管子底部，后来的数据压在管子口。因此深度优先的遍历方法是从图的一个顶点作为起点，将与顶点相邻的顶点压入栈，标记为已访问过。将栈顶的顶点弹出，查找与弹出的顶点相邻并未访问过得顶点，将这些顶点压入栈，后加入的顶点在

栈的顶点，先被弹出遍历。如此递归，直到栈中的所有顶点都被标记过，结束遍历。广度优先遍历方法则是结合队列和递归的特点遍历图。队列的数据结构特点则是类似于向圆筒中装羽毛球，圆筒有两个开口，一个用来拿出羽毛球，另一个用来向里面装羽毛球。先装的羽毛球在圆筒的前面，后装的羽毛球在圆筒的后面。所以广度优先遍历的过程是以图中的一个顶点为起点，标记为已访问，将与起点相邻的顶点标记为已访问，加入队列中。将队列头的顶点弹出，检测与弹出顶点相邻并且没有访问过的顶点，将它们排到队列的尾部。接着将队列头的顶点弹出检测，如此递归，直到队列中的所有元素都被访问过。

本课题主要先确认是否所有相机顶点会被遍历，因此选用深度优先遍历算法。将 cam_1 作为起点，并认为全局坐标系和 cam_1 的坐标系是对齐的。接着从 cam_1 开始遍历位姿图，在遍历完位姿图之后生成树。生成树（spanning tree）也可称为“花费树”。一个图的生成树就是通过最小数量的边连通图里面所有的顶点，且没有构成回路。在遍历过程中我们会检测是否所有的相机顶点都可以被遍历到，如果存在相机顶点无法被遍历，那说明我们的采集并筛选的数据可能有问题，存在相邻相机之间拍摄的标定图像不清晰，导致检测到无法检测到特征点。这时候我们可以将没有被遍历到的相机顶点以及和它相邻的相机顶点的图像再多选择几张，这些图像中的标定板清晰且最好位于两个相机中间。一般会解决有相机顶点无法遍历的问题。

遍历过生成树之后我们计算得到相机间的转化关系的初值，以及标定板在世界坐标系中位姿的初值。接着，我们要对相机间的外参做优化。外参优化的方法和上文一致，使用最小化重投影误差的方法优化外参。优化目标函数为

$$\mathbf{e}_{\text{reproj}}(\mathbf{p}^c, \mathbf{H}_{i,j}, \mathbf{K}_i) = \|\pi(\mathbf{p}^c, \mathbf{H}_{i,j}, \mathbf{K}_i) - \mathbf{p}^d\|^2 \quad (3-56)$$

其中 $\mathbf{K}_i$ 表示 cam_i 的内参； $\mathbf{H}_{i,j} = \mathbf{H}_i^{-1}\mathbf{H}_j$ ， $\mathbf{H}_j$ 表示位姿图中的顶点 i ，由图像构成的二元边 $\text{img}_{i,j}$ 是连接相机顶点 cam_i 和位姿顶点 pat_j 的。而 $\mathbf{H}_{i,j}$ 表示的是两个顶点间的转换关系。 $\mathbf{p}^c$ 表示的是标定图像上特征点的坐标，投影误差的目标函数是将 $\mathbf{p}^c$ 通过外参之间的转换关系将特征点转换到相应的相机坐标系中，再经过归一化平面，也就是投影到相机的物理成像平面中，接着通过相机的内参 $\mathbf{K}_i$ 将标定图像映射在相机的像素坐标系中。将映射后的结果和相机观测到的图像的特征点 $\mathbf{p}^d$ 的坐标做差，得到投影误差。得到的投影误差 $\mathbf{e}_{\text{reproj}}$ 是一个矢量，而目标函数应

该是一个标量，所以可以将它用平方形式表达。通常为了表达各个误差项的重要程度不一样，我们会把重投影误差项表达成 $\mathbf{e}_{\text{reproj}} \mathbf{\Omega} \mathbf{e}_{\text{reproj}}$ 。使用信息矩阵 $\mathbf{\Omega}$ 用来表达各个误差项的重要程度。信息矩阵 $\mathbf{\Omega}$ 是协方差矩阵的逆，其为一个对称的矩阵。信息矩阵中的每个元素都代表两个误差项的相关性，在本课题中为了简化问题将信息矩阵设置为单位矩阵。 π 是空间点向像素坐标系投影方程，目标函数和要优化的变量可以写为

$$\arg \min_{\mathbf{H}_i, \mathbf{C}_1, \mathbf{C}_i, i>1} \sum_{i>1} \sum_m \mathbf{e}_{\text{reproj}}(\mathbf{p}_k^c, \mathbf{H}_i^{-1} \mathbf{H}_j, \mathbf{C}_i) \quad (3-57)$$

其中优化的变量包括相机内参，以及顶点的位姿。其中 $i>1$ 是因为我们认为 cam_1 与实际坐标系是对齐的，所以 $\mathbf{H}_1$ 的位姿不需要优化，认为 $\mathbf{H}_1$ 一直是 $\mathbf{I}_{4 \times 4}$ 。最终应用 LM 方法求解出非线性最小二乘的最优解。

在求解最小重投影误差的过程中需要求解目标函数的雅可比矩阵。以位姿为例求解雅可比矩阵。如上文所述，列文伯格马夸尔特方法和高斯牛顿法一样都是对目标函数求取导，所以设误差为

$$e(\xi) = \pi(\mathbf{p}^c, \zeta, \mathbf{K}_i) - \mathbf{p}^d \quad (3-58)$$

其中 ζ 是李代数形式的转换向量，我们要求的是目标函数关于转换向量 ζ 的雅可比矩阵，我们通过链式求导法则逐步求取雅可比矩阵。

$$\mathbf{J}(\xi) = \frac{\partial \mathbf{e}(\xi)}{\partial \delta \zeta} = \frac{\partial \mathbf{e}(\xi)}{\partial \mathbf{p}^d} \frac{\partial \mathbf{p}^d}{\partial \mathbf{p}^c} \frac{\partial \mathbf{p}^c}{\partial \delta \xi} \quad (3-59)$$

我们将链式求导分成三个雅可比矩阵 $\mathbf{J}_1$ 、 $\mathbf{J}_2$ 、 $\mathbf{J}_3$ 。其中 $\mathbf{J}_1 = [\Delta x \ \Delta y]$ ，根据相机的内参投影矩阵可以得出 $\mathbf{J}_2$

$$\mathbf{J}_2 = \begin{bmatrix} \frac{f_x}{Z'} & 0 & -\frac{f_x}{Z'^2} X \\ 0 & \frac{f_y}{Z'} & -\frac{f_y}{Z'^2} Y \end{bmatrix} \quad (3-60)$$

通过扰动法，利用李群李代数求取^[39]

$$\mathbf{J}_3 = \begin{bmatrix} 1 & 0 & 0 & 0 & -Z & Y \\ 0 & 1 & 0 & Z & 0 & -X \\ 0 & 0 & 1 & -Y & X & 0 \end{bmatrix} \quad (3-61)$$

最终求取雅可比矩阵

$$\mathbf{J}(\xi) = \mathbf{J}_1 \mathbf{J}_2 \mathbf{J}_3 = \begin{bmatrix} \Delta x & \Delta y \end{bmatrix} \begin{bmatrix} f_x \frac{1}{Z} & 0 & -f_x \frac{X}{Z^2} & -f_x \frac{XY}{Z^2} & f_x (1 + \frac{X^2}{Z^2}) & -f_x \frac{Y}{Z} \\ 0 & f_y \frac{1}{Z} & -f_y \frac{Y}{Z^2} & -f_y (1 + \frac{Y^2}{Z^2}) & f_y \frac{XY}{Z^2} & f_y \frac{X}{Z} \end{bmatrix} \quad (3-62)$$

最终得到相机间的外参和每个相机的内参，如表 3-1 所示。

表 3-1 多相机外参和内参

相机	外参	内参
1	$\begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}$	$\begin{bmatrix} 533.0716 & 0 & 476.3566 \\ 0 & 533.4047 & 303.2456 \\ 0 & 0 & 1 \end{bmatrix}$
2	$\begin{bmatrix} 0.29191 & 0.10289 & -0.95090 & -0.16084 \\ -0.08211 & 0.99322 & 0.08226 & 0.01396 \\ 0.95292 & 0.05407 & 0.29837 & -0.11490 \\ 0 & 0 & 0 & 1 \end{bmatrix}$	$\begin{bmatrix} 536.721 & 0 & 482.8432 \\ 0 & 536.1922 & 300.7943 \\ 0 & 0 & 1 \end{bmatrix}$
3	$\begin{bmatrix} -0.79243 & 0.11629 & -0.59876 & -0.12835 \\ -0.02826 & 0.97360 & 0.22649 & 0.03913 \\ 0.60930 & 0.19640 & -0.76823 & -0.30768 \\ 0 & 0 & 0 & 1 \end{bmatrix}$	$\begin{bmatrix} 535.6985 & 0 & 480.412 \\ 0 & 535.389 & 302.6623 \\ 0 & 0 & 1 \end{bmatrix}$
4	$\begin{bmatrix} -0.83141 & -0.04169 & -0.55410 & 0.09262 \\ 0.08956 & 0.97409 & 0.20767 & 0.03645 \\ -0.54840 & -0.22229 & -0.80613 & -0.34104 \\ 0 & 0 & 0 & 1 \end{bmatrix}$	$\begin{bmatrix} 536.721 & 0 & 482.8432 \\ 0 & 536.1922 & 300.7943 \\ 0 & 0 & 1 \end{bmatrix}$
5	$\begin{bmatrix} 0.32926 & -0.12110 & 0.93644 & 0.18540 \\ 0.12931 & 0.98818 & 0.08232 & 0.01795 \\ -0.93534 & 0.09399 & 0.34103 & -0.11113 \\ 0 & 0 & 0 & 1 \end{bmatrix}$	$\begin{bmatrix} 540.7229 & 0 & 490.3264 \\ 0 & 540.2882 & 305.4171 \\ 0 & 0 & 1 \end{bmatrix}$

我们用可视化图像画出我们计算的相机间外参和标定板的位姿图像，如图

3-12 所示。通过可视化图像图 3-12，可以直观看出相机在世界坐标系中的位姿和我们实验平台上相机间的位置符合。通过计算得到的重投影误差为 0.5677，误差在允许范围内。多相机平台的标定结果满足我们的标定要求。




图 3-8 标定结果

3.4 本章小结

本章先描述了针孔相机的模型，以及从空间中的点投影到相机成像的归一化平面过程。接着通过内参将投影点从归一化平面映射到相机的像素平面。

然后通过相机拍摄的标定板图像和使用的随机噪声标定图像进行特征点的检测和匹配，通过匹配到的特征点的物理平面坐标 x 和 y 与相机拍摄的图像中的像素坐标 u 和 v 用来计算单应矩阵 $\mathbf{H}$ 。通过分解单应矩阵，求取相机的内参和标定板的位姿。接着我们使用最小化重投影误差优化相机的内参和标定板的位姿，通过重投影误差我们也可以量化我们单相机标定的误差。

有了标定板的位姿后，我们使用图论的知识构建了位姿图。认为正前方的相机的光心与世界坐标系原点对齐，令其位姿为单位矩阵。然后通过位姿图，以深度优先算法构建生成树，完成相机间转换关系的标定。最后使用重投影误差构建最小二乘问题，使用 LM 方法求解出最小投影误差，完成整个多相机平台内参和外参标定。

这一章我们解决了张正友教授的相机标定法中必须观测到多张完整的棋盘格标定板才能进行相机内参和外参标定的问题。同时，以往多相机间的外参标定中，相机的视角都是向内的，共同视野比较大。我们这章也解决了课题中相机的视角朝外，相机间共同视野少的问题。最后通过标定可视化结果中观察以及重投影误差的计算，标定结果符合要求。

第4章 单相机和激光雷达标定及联合标定

4.1 引言

通过前几章的工作，我们计算得到相机的内参和相机间的转换关系。本章将阐述激光雷达点云数据的特点，标定平面的确定和平面法线的计算，以及相机和激光雷达之间的转换关系的计算。其中，我们设计了一个软件来简化标定过程。最后通过相机和激光雷达之间的转换关系以及相机和相机间的转换关系完成激光雷达和整个多相机平台的转换关系的计算。

4.2 激光雷达基本原理

激光雷达也称光学雷达，或简称光达（LIDAR），是光学遥感技术在测量距离方面的应用。目前激光雷达主要分为两个类型，扫描式激光雷达和非扫描式激光雷达。扫描式激光雷达又分为机械旋转式的激光雷达、固态激光雷达、基于 MEMS 的激光雷达以及相控激光雷达。目前在自动驾驶中应用最广泛的激光雷达是机械旋转式的激光雷达，我们课题中选用的就是 32 线的机械旋转式的激光雷达。机械式激光雷达主要由激光发射装置、激光反射后的接收装置、对接收到的信号进行处理的装置和使这三个装置可以协同工作的机构组成。如图 4-1 是机械式激光雷达的激光发射器向不同的方向发射激光的示意图。




图 4-1 激光雷达发射系统

当激光打在物体上发生反射，接收装置接收激光的反射信号，通过光电探测装置根据反射激光能量的强弱转换成不同大小的电信号，再通过信号处理装置对

接收到的信号进行处理得到每个点的位置和反射强度。




图 4-2 激光雷达工作示意图

激光雷达在距离的测量上主要有两种算法，一种是三角法^[40]一种是 TOF^[41]法。三角法的原理是激光发射器发射激光，打在物体后，反射的光信号由线性激光接收器接收，由于激光发射器和激光接收器之间有一段距离，依照光学路径，不同距离的物体在激光接收器上的接收位置不同。按照三角公式进行计算就能计算出物体的距离。但是由于测量的物体距离激光雷达越远，反射的激光在接收器中的距离就越小，当距离大于一定距离之后，反射的激光在接收器中由于差距太小无法分辨。所以从原理上这种方法无法测量远距离的物体，但是在自动驾驶中我们需要对远距离的物体进行提前感知识别以便可以及时做出决策。所以应用在自动驾驶中的激光雷达的距离测量用的是另一个算法，飞行时间（Time Of Flight）。飞行时间的计算方法如下图




图 4-3 飞行时间测距方法

从图 4-3 中可以看出飞行时间方法测距的原理更简单 $s = c \times t$ ，其中 s 表示我们要测量的距离； c 是一个常数为 $3 \times 10^8 m/s$ 表示光的传播速度； t 表示激光从发出到接收所间隔的时间。最后通过信号处理部分将激光接收器接收到的反射信号转

换成点云数据。如图 4-3 所示，是激光雷达采集的数据在自动驾驶中的应用，左图是应用在道路的感知中，右图是通过激光雷达构建高精度的点云地图。




图 4-4 激光雷达数据

我们选用的 RoboSense 的 32 线激光雷的出点数是 640,000pts/s，也就是一秒钟会反馈 640,000 个点，每个点包含的信息有点在激光雷达坐标系中的空间坐标 (x, y, z) ，以及每个点的反射率。在本课题中反射率暂时用不上，但是在自动驾驶的感知等方向会用到。图 4-5 是我们使用的 32 线激光雷达，及其位于车辆顶端工作的示意图。通过激光雷达的扫描，我们可以分辨出点云数据中的物体是什么，接下来我们需要选取点云中打在标定板上的点进行平面估计。



图 4-5 激光雷达及其应用示意图

4.3 确定点云中标定板平面

针对单相机和激光雷达的外参的标定，我们的解决方法是通过选取点云中打在标定板上的点云，计算在激光雷达坐标系中标定平面的方程和平面的法向量。计算在相机坐标系中标定板的位姿并计算标定板所在平面的法向量。通过两个平面

的间的法向量和点云到平面距离的和最小计算出相机坐标系和激光雷达坐标系之间的转换关系，最后利用外参变换后的点到平面距离最小优化外参。本节将描述如何计算点云数据中标定板的平面方程。

我们使用的 32 线激光雷达的旋转频率是 10Hz，而激光雷达的出点率是 640,000pts/s，所以我们使用标定点云数据中每一帧中大概有 64000 个点。在 64000 个点中找到打在标定平面上的一小部分点目前没有合适的算法完成这份工作。但是，要计算点云数据中的标定板平面方程，我们还需要从一帧点云找到打在标定板上的点。我们使用人工选择点云的方式。在一帧点云中，我们可以根据标定板的形状以及在点云图中和图片对应的标定板位姿变化来选择打在标定板上的点云。在点云中选择我们指定点周围的点云是使用了 PCL 库中的 KD-tree 方法。KD-tree 也称为 K 维树，是一种计算机科学中的数据结构，用来组织表示 k 维空间中点集合^[42]。它是一种有其他约束影响的二叉搜索树。KD-tree 对于区间和近邻搜索很有效。在我们课题中，我们的点是三维点，所以我们在三个维度进行处理。设置半径，检测半径内的点云。如果半径内的点云个数少于 3 个，无法解出空间平面的方程，因此会重新选择。其中，打在标定板边边缘的点波动比较大，容易使结果不准确。而打在板上的点足够多，满足我们的计算要求。因此，我们选择打在标定板中心点，这样找到的点更多。如图 4-6 所示，左图是一张没有被选择的图，右图的右下角是我们选择在打在标定板平面上的点。




图 4-6 点云数据中选点

接着我们通过所选的点云计算标定板平面方程。常用的平面拟合方法有最小二乘法和随机抽样一致算法（RANSAC）^[43]也称随机采样一致算法。最小二乘法认为数据点应该是在真实平面附近波动，通过将误差最小化的优化方法使得到的结果最接近理想值。但是这种方法的一个限制条件是如果数据中有大量的异常值，在最小化的过程中由于有大量的异常，会导致整个结果的误差变大。另一种随机抽样一致算法拟合标定板的平面，随机抽样一致算法是一种通过迭代的方式从已

知的数据中估计模型参数的方法。随机抽样一致算法是一种不确定的算法，更多次的迭代会一定程度上提升算法的准确性。该算法将数据分为两类：一种是局内点（inliers），另一种是局外点（outliers）。局外点顾名思义就是对模型估计没有贡献的点，通过设置局外点可以排除数据异常的点。局内点是满足一定阈值的对模型估计有帮助的点。在算法开始的时候规定一个较小的局内点，存在一个可以估计的参数模型，并且该模型能够适应初始的小规模的局内点。

在本课题中，我们对比了两种算法。我们先实验随机抽样一致算法，设拟合的平面方程为 $0 = ax + by + cz + d$ ，其中 a, b, c, d 为待拟合的参数。根据待拟合的参数个数为四个，所以我们要想初始化平面方程就需要四个点来计算出平面方程。因此，我们在所选的打在标定板上的点云中随机选择四个点，通过所选的四个点计算出拟合的平面方程。接着将其他点的空间坐标代入式（4-1）计算点到拟合平面的距离。

$$D = \frac{|ax_0 + by_0 + cz + d|}{\sqrt{a^2 + b^2 + c^2}} \quad (4-1)$$

距离大于设置阈值的点，我们认为这些点为局外点，留下距离比阈值小的点并标记为局内点。我们设置迭代的次数为 1000 次，统计局内点有多少个。最后，对比每一次迭代中局内点的个数，找到所有拟合平面上点最多的。认为局内点最多的拟合平面从概率角度考虑认为该平面最有可能是真实平面，该平面的参数就是最接近真实值的平面方程参数。如图 4-7 所示是随机抽样一致在 200 个点中拟合平面得到的结果。其中圆圈表示局外点，加号表示局内点，最终我们可以得到拟合的平面方程。




图 4-7 RANSAC 拟合平面

从图中可以看出当点云数据很多，并且周围环境很复杂的情况下，随机提取

一致算法可以很好的在复杂无序的点云数据中找到平面方程。

最小二乘法用来平面拟合也称为三维法向量估计，基本思路为假设平面过原点，设平面方程为

$$ax + by + cz = 0 \quad (4-2)$$

假设平面过重心，对于我们所选的点云数据到过重心的平面有

$$d = a(x_i - \bar{x}) + b(y_i - \bar{y}) + c(z_i - \bar{z}) \quad (4-3)$$

其中 $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ ， $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$ ， $\bar{z} = \frac{1}{n} \sum_{i=1}^n z_i$ 分别为所选点云数据的重心的三维坐标。

接着对括号中的操作就是对数据进行去重心处理，将数据的坐标原点移动到数据重心。为了书写简便，我们令 $x_i = x_i - \bar{x}$ ， $y_i = y_i - \bar{y}$ ， $z_i = z_i - \bar{z}$ ，最后构建最小二乘的目标函数为

$$\min D = \min d^2 = \min \sum_{i=0}^{n-1} (a_i x + b_i y + c_i z)^2 \quad (4-4)$$

对(4-4)求导可得

$$\begin{aligned} \frac{\partial D}{\partial a} &= 2x_i \sum_{i=1}^n (ax_i + by_i + cz_i) \\ \frac{\partial D}{\partial b} &= 2y_i \sum_{i=1}^n (ax_i + by_i + cz_i) \\ \frac{\partial D}{\partial c} &= 2z_i \sum_{i=1}^n (ax_i + by_i + cz_i) \end{aligned} \quad (4-5)$$

写成矩阵形式并令导数为零可得

$$\begin{bmatrix} \sum_{i=1}^n x_i^2 & \sum_{i=1}^n x_i y_i & \sum_{i=1}^n x_i z_i \\ \sum_{i=1}^n x_i y_i & \sum_{i=1}^n y_i^2 & \sum_{i=1}^n y_i z_i \\ \sum_{i=1}^n x_i z_i & \sum_{i=1}^n y_i z_i & \sum_{i=1}^n z_i^2 \end{bmatrix} \begin{bmatrix} a \\ b \\ c \end{bmatrix} = 0 \quad (4-6)$$

根据上文中所述求此最小二乘问题，对左边对称矩阵 SVD 分解，最小的特征值对应的特征向量即为平面方程系数的解。如图 4-6，我们随机生成的 200 个三维点，用最小二乘法拟合平面方程，法线最小二乘法拟合的平面不一定保证在平面上点




图 4-8 最小二乘拟合平面

最多，但是充分考虑每个数据点及其可能带来的误差，最后拟合出平面方程。

对比两种方法我们可以看出它们各自的特点。随机抽样一致算法在点云环境比较复杂，比如一帧点云中打在树上的点比较多，这时候有些点的曲率比较大，想要从这种环境比较复杂的点云中找到地面所在的平面。或者我们所使用的数据中异常值比较多，很难利用所以数据时。这些情况使用随机抽样一致算法比较合适。最小二乘算法的特点是考虑到每个数据都是围绕真实值波动的，都是有价值的数，最后利用所有数据拟合出平面。在我们的课题中，由于我们已经从复杂的点云数据中筛选出了打在标定板上的点，并且将标定板边缘的点剔除了，所以剩下的点云数据较平稳，没有异常值。因此针对我们的课题，最后选择最小二乘法计算平面的方程。

4.4 确定图像中标定板平面




图 4-9 棋盘格标定板

图 4-7 是我们用来确定标定板在相机坐标系下的位姿所使用的棋盘格标定板。我们需要输入棋盘格行和列中的黑白格的个数，一般将行和列中的格子数设置为不同，以便区分行和列。我们需要输入棋盘格中的内焦点的个数，所谓内焦点就除了挨着纸边的一圈角点外剩下的角点。如图 4-7 中的内焦点是 6×4 。我们还需要输入每个格子的实际尺寸，为了确定棋盘格的尺寸以及外参的尺度。

标定的第一步就是确定棋盘格中的内角的位置。由于棋盘格的图案单一，我们用计算更快效果更好的角点检测方法^[44]。所谓角点就是图像轮廓之间的交点，在同一个场景中，比如从不同的视角观测同一栋楼，角点的特性几乎不变，并且通常角点周围的像素值得梯度下降的幅值很大。我们使用窗口函数在图像中滑动，如果在像素值波动不是很大的区域，那么计算前后图像的灰度值变化很小。如果窗口函数位于图像轮廓的边缘，窗口平行于轮廓边缘滑动，滑动前后图像的灰度值变化很小。如果是垂直于轮廓边缘滑动，图像前后的灰度值变化就会很大。如果窗口函数位于角点位置，那么无论向哪个方向滑动窗口，图像的像素值变化都会很大。这也是角点检测的基本思路。所谓的窗口函数是一个 $n \times n$ 的系数矩阵，当窗口滑动的方向为 $[u, v]$ 时，经过窗口滑动前与滑动后像素值的变化方程为

$$E(u, v) = \sum_{(x, y) \in W} w(x, y) [I(x+u, y+v) - I(x, y)]^2 \quad (4-7)$$

其中 W 是窗口函数， $[u, v]$ 是窗口的偏移量， (x, y) 是 W 所对应的像素坐标的位置，窗口函数有多少行和列，就有多少个坐标位置。 $I(x, y)$ 是像素坐标为 (x, y) 的图像灰度值， $I(x+u, y+v)$ 是像素坐标为 $(x+u, y+v)$ 的图像灰度值。 $w(x, y)$ 是窗口函数，最容易的处理方式就是我们将 W 内的权重系数都设置为 1，但是这样无法提现出周围像素点对中心像素点的影响。因此，我们会把 $w(x, y)$ 函数的权重系数设置为以 W 为中心的多元正态分布。如果窗口 W 的中心是角点，那么窗口在滑动前后中心点对灰度的变化的贡献都是最大的，根据高斯函数的性质，在 3σ 外的像素值对灰度的变化几乎没有影响。

从式(4-7)可以看出来，如果窗口滑动在图像平缓的区域，比如在白格子或者黑格子中，像素的变化几乎不变， $E(u, v) = 0$ 。如果在棋盘格的角点位置，无论窗口向哪个方向滑动， $E(u, v)$ 的值都会很大。我们根据 $E(u, v)$ 的大小来检测角点的位置。

接着需要对 $E(u, v)$ 函数进行化简，对 $E(u, v)$ 使用泰勒展开公式得：

$$\begin{aligned}
 E(u, v) &= \sum_{(x, y) \in W} w(x, y) [I(x+u, y+v) - I(x, y)]^2 \\
 &= \sum_{(x, y) \in W} w(x, y) [I(x, y) + uI_x + vI_y - I(x, y)]^2 \\
 &= \sum_{(x, y) \in W} w(x, y) [u^2 I_x^2 + 2uv I_x I_y + v^2 I_y^2] \\
 &= \sum_{(x, y) \in W} w(x, y) \begin{bmatrix} u & v \end{bmatrix} \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix} \begin{bmatrix} u \\ v \end{bmatrix} \\
 &= \begin{bmatrix} u & v \end{bmatrix} \left(\sum_{(x, y) \in W} w(x, y) \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix} \right) \begin{bmatrix} u \\ v \end{bmatrix}
 \end{aligned} \tag{4-8}$$

将中间项简写为 M ，则式 (4-8) 可以写为

$$E(u, v) = \begin{bmatrix} u & v \end{bmatrix} \mathbf{M} \begin{bmatrix} u \\ v \end{bmatrix} \tag{4-9}$$

其中 I_x, I_y 是窗口函数 W 里面的像素点分别在 x 轴方向上和 y 轴方向上的梯度值。接着我们通过对窗口 W 内的像素点求取 x 轴方向和 y 轴方向的梯度并进行梯度统计分析。以 I_x 和 I_y 为横纵坐标轴，将每个像素点的梯度放在坐标系中表示为 (I_x, I_y) 。如图 4-8 所示，是计算图像中的边缘，平坦区域和角点三种图像在 x 轴方向和 y 轴方向梯度的示意图。




图 4-10 梯度计算示意

如图 4-9 所示,平坦区域上的每个像素点所对应的梯度 (I_x, I_y) 聚集在原点附近,这是因为平坦区域的像素点他们的梯度方向虽然不同,但是它们的幅值变化都不会很剧烈,因此都在分布在原点的较近的地方。边缘区域的梯度点会沿着其中一个周分散,如果是水平方向或者垂直方向,那么梯度点就会沿着 I_y 轴或者 I_x 轴方向分散。对于角点区域的梯度点,无论是水平方向还是垂直方向,梯度变化都很大,所以梯度点的分布很分散。




图 4-11 梯度分布

我们之前用 $\mathbf{M}$ 矩阵表示了梯度矩阵

$$\mathbf{M} = \sum_{(x,y) \in W} w(x,y) \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix} = \begin{bmatrix} A & C \\ C & B \end{bmatrix} \quad (4-10)$$

设 I_x, I_y 为两个字段,对于矩阵 $\mathbf{M}$ 首先对其各个维度进行均值化,因此每个维度的随机变量的平均值都变成零,也因此简化了协方差矩阵。我们的目的是分析数据的主要成分,我们对协方差矩阵 $\mathbf{M}$ 进行对角化,对角线上的值就是各个字段的方差。我们求取矩阵 $\mathbf{M}$ 的特征值,如果 I_x 和 I_y 的特征值都比很大,说明像素点的梯度分布很分散;如果所对应的特征值都比较小,说明窗口区域内的像素点的梯度幅值非常小;如果两个特征值一个比较大一个比较小,这说明像素点在某个方向的梯度幅值变化明显,符合边缘在窗口函数中的特点。利用 OpenCV 在棋盘格上进行角点检测的结果如下




图 4-12 棋盘格角点检测

从图 4-10 中可以看出，可以将标定板上的角点都检测出来，但是如果单纯的进行角点检测，如 4-10 右图所示，不仅会检测出棋盘格的内角点，也会误检测出棋盘格的外角点，因为我们所用打印棋盘得物体的尺寸限制，边缘的棋盘格很难形成正方形，因此我们需要将外角点滤除。同时左图中可以看出，除了检测到棋盘格的角点外，还会检测到图像中其他位置的角点，为了不重复造轮子，我们使用 OpenCV 的函数检测棋盘格的角点。具体做法为，首先因为我们使用的棋盘格是黑白的，所以对图像进行二值化，方便找到棋盘格角点。所谓二值化就是找到一个阈值，当像素高于这个阈值认为该点像素为白色，低于阈值认为该点像素为黑色。一种局部平均自适应阈值化方法对于图像中亮度不均匀情况适应性很强，使用该方法对图像二值化可以得到理想的阈值。接着对白色的像素点进行膨胀处理，白色像素点膨胀后可以使黑色的棋盘格缩小，使得相互连接的黑色棋盘格分离。分离成一个个不连接的棋盘格后进行多边形变形检测，判断是否是四边形。接着使用长宽比、周长和面积等约束去除干扰的四边形。在多边检测中首先对我们二值化后的图像进行轮廓提取、边缘提取。接着通过对轮廓外形无限逼近，删除非关键点、得到轮廓的关键点，不断逼近轮廓真实形状^[45]。在得到一个个的四边形之后，由于我们要找的是内角点，因此将每个四边形作为一个整体，判断四边形周围有没有四边形。如果没有临近四边形，认为是干扰四边形，两个临近四边形为边界四边形，四个邻近四边形为内部四边。按照邻近关系对四边形排序，根据输入的内角点个数筛选出内部四边形。最后检测出角点。角点检测的效果如下图所示



图 4-13 棋盘格内角点检测

在确定了内角点的位置后为了使标定更准确，我们会使用亚像素级角点检测。所谓亚像素级检测是因为我们前几步的检测到的角点位置都是在像素坐标系中的整数坐标，而整数位置并不准确。为了达到更准确的位置，需要精确到浮点坐标位置。求取亚像素点的坐标的方法就是向量的点乘理论，即两个向量如果垂直那么两向量点乘为零。如图 4-12 左图所示 q 点为我们待求的亚像素点， p 点是我们计算的角点及其周围的点。设 p 点是在平坦区域如 p_1 ，则其梯度值为 0，则 $\overrightarrow{qp_1}$ 向量点乘 p_1 的梯度为 0。若 p 点位于边缘 p_2 ，则其梯度方向如图 4-12 中右图所示，




图 4-14 亚像素检测

$\overrightarrow{qp_2}$ 向量点乘 p_2 点的梯度为 0。根据此特点取构建最小二乘问题，选取我们计算得到的角点及其周围的点计算梯度，与 $\overrightarrow{qp}$ 向量点乘为 0。最后求解出亚像素点。通过 OpenCV 计算出的亚像素点如图 4-13




图 4-15 亚像素检测结果

其中红色为计算出的亚像素位置，绿色为我们检测出的角点位置。通过上面几个步骤之后已经得到了角点的坐标。通过第三章中所述的单应矩阵的计算，我们可以计算出标定板在相机坐标系中位姿。在点云数据中，我们通过最小二乘法也计算得到了标定板在激光雷达坐标系中的位姿。有了位姿后，我们设在标定板坐标系中标定板所在的平面的法线向量为 $[0,0,1]$ 。利用我们计算得到的标定板位姿矩阵计算出在相机坐标系中标定板中心的法向量。在激光雷达坐标系中，我们通过最小二乘方法已经计算出标定板所在平面的方程。在选择点云时我们以一定的半径选择点云数据，因此可以计算出圆心处的平面法向量矩阵。接着计算出两个法向量的转换关系，法线的转换关系推导如式（4-11）所示

$$\begin{aligned} \mathbf{R}\mathbf{N} &= \mathbf{M} \\ \mathbf{R}\mathbf{N}\mathbf{N}^T &= \mathbf{M}\mathbf{N}^T \\ \mathbf{R} &= \mathbf{M}\mathbf{N}^T(\mathbf{N}\mathbf{N}^T)^{-1} \end{aligned} \quad (4-11)$$

其中 $\mathbf{R}$ 为法向量间的旋转矩阵， $\mathbf{N}, \mathbf{M}$ 是两个法向量矩阵。由于我们有多组点云和图像位姿的对应关系，可以写成一个线性矩阵的形式。虽然无法得到精确的解析解，但是可以得到相对精确的近似解。如第三章中所述，通过 SVD 分解最小二乘系数矩阵，对特征值进行排序找到最小的特征值对应的特征向量，得到相应旋转矩阵的解。

接着通过两个法向量之间的转换关系和两个平面之间的转换关系计算出相机和激光雷达之间的转换关系。 $\mathbf{N}^T\mathbf{p}=0$ ， $\mathbf{p}$ 为平面上的点。设在变换后的平面点为 $\mathbf{p}'$ ， $\mathbf{p}$ 和 $\mathbf{p}'$ 之间的转关系为 $\mathbf{p}'=\mathbf{M}\mathbf{p}$ 。在变换后得到新平面的法向量矩阵为 $\mathbf{N}'$ ，设变换后的法向量和之前的法向量之间的关系为 $\mathbf{p}'=\mathbf{S}\mathbf{p}$ ，由法向量和平面的关系可得

$$(\mathbf{N}')^T \mathbf{p}' = 0 \Rightarrow (\mathbf{S}\mathbf{N})^T \mathbf{M}\mathbf{p} = 0 \Rightarrow (\mathbf{N})^T \mathbf{S}^T \mathbf{M}\mathbf{p} = 0 \quad (4-12)$$

从等式（4-12）可以得出满足等式成立的条件有 $\mathbf{S}^T \mathbf{M} = \mathbf{I}$ ，左乘 $\mathbf{M}^{-1}$ 并取转置可得 $\mathbf{S} = (\mathbf{M}^{-1})^T$ 。

在得到旋转矩阵后将旋转矩阵固定，并将相机坐标系中的标定板平面通过旋转矩阵旋转到激光雷达坐标系中。计算我们所选的点云到旋转平面的距离，通过最小化所有点云到平面的距离优化出两个坐标系之间的平移关系。将旋转矩阵和平移矩阵写成齐次式得到两个坐标系之间的转换关系。




图 4-16 转换关系示意图

接着通过转换关系将标定板在相机坐标系下的位姿直接转换到激光雷达坐标系中，再利用所选点云数据到转换平面的距离和最小优化相机和激光雷达之间的外参。由于我们是人工选择打在标定板平面上的点云，所以在选择的时候会存在人为的选择点云的误差。所以在整个标定进行一次后我们要对所选的点云进行修正，也就是通过观察点云投影到标定板图像上的点是否位于标定板上。

为了使这个过程简便可视化，我们用 Qt 设计了一个软件来进行标定。Qt 可以为应用程序开发者提供友好的图形界面所需的功能。它是完全面向对象的，易扩展并且允许组件编程。在本课题中我们将界面设计成图 4-15 所示




图 4-17 标定软件界面

在图 4-15 中可以看到我们设计的标定软件，在界面中我们输入棋盘格的尺寸。例如我们使用的棋盘格的内角点个数是 6×8 ，每个格子都是正方形的，实际打印出来的尺寸边长为 0.096727m。接着我们需要使用键盘调整右侧点云图中的视角，找到打在标定板上的点云，调整视野将标定板点云足够大。




图 4-18 调整点云图视野

在数据播放过程中我们对图像中的每个位姿都通过点击 Grad 按钮进行位姿图片和点云的抓取，共 90 个位姿。抓取的数据如下图




图 4-19 抓取图像和点云数据

将所有位姿都抓取结束后我们需要在点云图中找到打在标定板上的点云。当我们把鼠标放在标定板上时,会出现一个绿色的圆和两条绿色的线,其中一条线(法向量)过圆心且垂直于该平面,另外一条是平行于该圆面的,可以根据图像中标定板的姿态,来判断该法向量是否有明显偏差;点击鼠标左键选中圆形区域,点击右键取消选中。将所有的位姿都选择结束后,点击右上角的 **Calibrate** 按钮,计算相机和激光雷达之间的外参。计算结束后点击 **Project** 按钮,就可以将我们选择的点云投影到图片上,如下图所示




图 4-20 投影点云

如果投影到图片上的点云偏离标定板的中心位置,那么我们在该帧点云中重新标记相应帧的点云区域。然重复点击 **Calibrate** 和 **Project**,直至所有的图片上投影的点云都位于标定板的中心区域。如果个别帧投影的点云始终无法很好的落在标定板的中心区域,可以将该帧数据通过点击 **Remove** 删除该帧数据。然后重新抓取

该位姿的数据，最后投影都位于标定板中心后，点击 Save 保存标定结果。

最后相机和激光雷达的之间的外参在软件的左上角 CameraExtrinsicMat 可以看到，相关的外参参数也被保存在了 yaml 文件中。

	CameraExtrinsicMat	CameraMat	DistCoeff	ImageSize
	1	2	3	4
1	0.0158889	-0.130465	0.991326	-0.239521
2	-0.999568	0.0224296	0.0189729	-0.068513
3	-0.0247103	-0.991199	-0.130053	-0.136806
4	0	0	0	1

图 4-21 相机和激光雷达外参

Chessboard Points	Chessboard Normals	CalibrationError
0.417494, 0.00390487		

图 4-22 外参标定误差

4.5 联合外参

在第三章中计算得到了相机间的外参，我们以相机 1 的光心为全局坐标系的原点，计算得到了其他相机在全局坐标系中的位姿。在第四章中我们计算出了相机 1 和激光雷达之间的外参。最后我们通过相机 1 可以将激光雷达和其他四个相机之间的外参通过矩阵相乘的方式计算得到。其结果如下

$$\begin{bmatrix} 0.00801 & -0.13236 & 0.99117 & 0.14237 \\ -0.99997 & -0.00100 & 0.00794 & 0.00506 \\ -0.00005 & -0.99120 & -0.13236 & -0.05234 \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (4-13)$$

$$\begin{bmatrix} 0.95579 & -0.03692 & 0.29173 & 0.09041 \\ -0.29173 & -0.12234 & 0.94793 & 0.25546 \\ 0.00069 & -0.99180 & -0.12692 & -0.04408 \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (4-14)$$

$$\begin{bmatrix} 0.57414 & -0.10631 & -0.81182 & -0.18372 \\ 0.81875 & -0.06946 & 0.56994 & 0.13189 \\ 0.00420 & -0.99190 & -0.12692 & -0.04407 \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (4-15)$$

$$\begin{bmatrix} -0.94644 & -0.04607 & 0.31957 & -0.04428 \\ -0.31957 & 0.04428 & -0.32276 & 0.10887 \\ 0.00852 & -0.99298 & -0.11791 & -0.09925 \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (4-16)$$

$$\begin{bmatrix} -0.59721 & 0.09529 & -0.79640 & -0.18131 \\ 0.80208 & 0.07351 & -0.59267 & -0.14252 \\ 0.00207 & -0.99273 & -0.12033 & -0.08313 \\ 0 & 0 & 0 & 1 \end{bmatrix} \quad (4-17)$$

式(4-13)、(4-14)、(4-15)、(4-16)、(4-17)分别是激光雷达与正前方相机、左前方相机、左后方相机、右前方相机、右后方相机之间的转换关系。

通过激光雷达和多相机平台之间的转换关系，将点云投影到图像平面上，可得到结果如图



图 4-23 左前方相机和左后方相机标定结果



图 4-24 右前方相机和右后方相机标定结果




图 4-25 正前方相机标定结果和激光雷达数据

从五个投影图中可以看出，正前方的相机 1 的融合数据是使用的标定数据，其融合效果较好。其他四个相机的融合数据是使用的标定多相机时采集的数据，由于标定板距离激光雷达很近所以会有一定的误差存在。但是绝大部分点云数据在标定边缘有明显的断层的现象，从融合的结果说明通过我们的标定和转换关系的联合得到的标定结果是准确的。

4.6 本章小结

在本章我们首先阐述了激光雷达是如何计算探测物体距离激光的距离以及激光雷达运行的基本原理。介绍了我们所选用的激光雷达的特点，为何要在点云中人工选取打在标定板上的点云。

接着我们阐述了通过所选的已知点云数据计算标定板平面的两种方法：一种是随机抽样一致算法，类似于投票的算法。该算法适合在所选的点规律不是很明显的情况下找到最有可能的平面方程。另一种方法是最小二乘的方法，通过最小化所有点到平面的距离优化出点云所在平面的方程。结合我们的点云数据采用最小二乘法计算出标定板平面方程。

在相机坐标系中通过角点检测、四边形检测、相邻四边形的个数等方法得到棋盘格标定板中的内角点。再通过亚像素角点检测计算出更精确的亚像素点坐标。通过前文介绍的平面间的单应性计算出标定板位姿。

通过两个平面的法向量计算出两个平面间的旋转矩阵，接着通过最小化点云点到平面的距离计算出两个坐标系间的平移，最后可以得到两个坐标系之间的转换关系。

由于要多次在点云中选择标定板上的点云，为了简化标定过程我们设计了一

个标定软件，在本章中我们介绍了标定软件的使用过程。

最后将激光雷达和相机之间的外参，多相机之间的外参联合，完成整个系统的标定。

结 论

本文对应用在自动驾驶感知模块的激光雷达和多相机平台的标定方法进行了研究。该平台是由一个 32 线的激光雷达和五个相同型号的工业级相机组成。根据课题的要求标定相机的内参，相机间的外参，相机和激光雷达间的外参。目前对于相机的镜头朝外，相邻相机间共同视野很少的情况下的标定方法很少。激光雷达和相机之间的标定过程很繁琐，优化的标定方法也较少。针对以上问题本文优化了标定的过程和结果，使得标定更精确且可视化。本文的主要研究工作如下：

(1) 多相机标定和激光雷达与相机标定的数据采集、同步和处理。多相机平台标定数据需要用标定板在相机视野范围内绕着平台一周，激光雷达和相机的标定数据需要用棋盘格标定板在相机视野内的九个位置采集九十个位姿图像。将采集的数据进行时间同步，并剔除无用的数据。

(2) 多相机平台的标定。输入相邻两相机同时拍摄到的标定板图像，以及标定板的物理尺寸。通过特征提取与匹配将拍摄图像与生成的标定图像建立联系，通过两个平面间转换关系的单应性计算出单应矩阵。通过对单应矩阵的分解求解出相机的内参和标定板在相机坐标系中的位姿，使用最小化重投影误差方法优化内参和外参，接着使用图优化的方法得到相机间的外参。

(3) 相机和激光雷达的标定。选择每个位姿点云数据中打在标定板上的点云，计算标定板位姿和法向量矩阵。使用角点检测等方法计算标定板在相机坐标系中的位姿和法向量矩阵。通过法向量计算两个平面旋转矩阵，利用所选点云点到平面距离和最小优化出平移矩阵，完成外参标定。

(4) 将相机之间的外参和激光雷达与相机间的外参联合，完成整个系统的标定。

本课题中存在一些尚未解决的问题，在相机和激光雷达的标定中需要 90 个标定板的位姿数据，这一步的工作量还是比较大的。在今后的工作中可以通过增加转台的方式减少在数据采集过程中不断的拿着标定板移动。

参考文献

- [1] 杨明. 无人自动驾驶车辆研究综述与展望[J]. 哈尔滨工业大学学报, 2006, 38 (8): 1259-1262.
- [2] DICKERMAN L, HARRISON J. A new car, a new grid[J]. IEEE Power and Energy Magazine, 2010, 8 (2): 55-61.
- [3] POCZTER S L, JANKOVIC L M. The google car: driving toward a better future?[J]. Journal of Business Case Studies (Online), 2014, 10 (1): 7.
- [4] DAILY M, MEDASANI S, BEHRINGER R, et al. Self-driving cars[J]. Computer, 2017, 50 (12): 18-23.
- [5] MITCHELL H B. Multi-sensor data fusion: an introduction[M]. [S.l.]: Springer Science & Business Media, 2007.
- [6] DAVISON A J, CID Y G, KITA N. Real-time 3d slam with wide-angle vision[J]. IFAC Proceedings Volumes, 2004, 37 (8): 868-873.
- [7] ZHANG Z. A flexible new technique for camera calibration[J]. IEEE Transactions on pattern analysis and machine intelligence, 2000, 22.
- [8] BOUGUET J Y. Camera calibration toolbox for matlab[J]. [http://www. vision. caltech. edu/bouguetj/calib_doc/index. html](http://www.vision.caltech.edu/bouguetj/calib_doc/index.html), 2004.
- [9] STOYANOV D. Camera calibration tools[J]. 2006.
- [10] SCARAMUZZA D, MARTINELLI A, SIEGWART R. A toolbox for easily calibrating omnidirectional cameras[C]//2006 IEEE/RSJ International Conference on Intelligent Robots and Systems. [S.l.]: IEEE, 2006: 5695-5701.
- [11] MEI C, RIVES P. Single view point omnidirectional camera calibration from planar grids[C]//Proceedings 2007 IEEE International Conference on Robotics and Automation. [S.l.]: IEEE, 2007: 3945-3950.
- [12] BARRETO J, DANIILIDIS K, KELSHIKAR N, et al. Easycal camera calibration toolbox[J]. Univ. Pennsylvania, Philadelphia, PA, USA, Tech. Rep, 2003.
- [13] TSAI R Y, LENZ R K. A new technique for fully autonomous and efficient 3d robotics hand/eye calibration[J]. IEEE Transactions on robotics and automation, 1989, 5

- (3): 345-358.
- [14]SHIU Y C, AHMAD S. Calibration of wrist-mounted robotic sensors by solving homogeneous transform equations of the form $ax = xb[J]$. *IEEE Transactions on Robotics and Automation*, 1989, 5 (1): 16-29.
- [15]LI B, HENG L, KOSER K, et al. A multiple-camera system calibration toolbox using a feature descriptor-based calibration pattern[C]//2013 IEEE/RSJ International Conference on Intelligent Robots and Systems. [S.l.]: IEEE, 2013: 1301-1307.
- [16]LEVINSON J, THRUN S. Automatic online calibration of cameras and lasers.[C]//Robotics: Science and Systems: volume 2. [S.l.: s.n.], 2013.
- [17]RODRÍGUEZ-GARAVITO C, PONZ A, GARCÍA F, et al. Automatic laser and camera extrinsic calibration for data fusion using road plane[C]//17th International Conference on Information Fusion (FUSION). [S.l.]: IEEE, 2014: 1-6.
- [18]LYU Y, BAI L, ELHOUSNI M, et al. An interactive lidar to camera calibration[J]. *arXiv preprint arXiv:1903.02122*, 2019.
- [19]VASCONCELOS F, BARRETO J P, NUNES U. A minimal solution for the extrinsic calibration of a camera and a laser-rangefinder[J]. *IEEE transactions on pattern analysis and machine intelligence*, 2012, 34 (11): 2097-2107.
- [20]ZHANG Q, PLESS R. Extrinsic calibration of a camera and laser range finder (improves camera calibration)[C]//2004 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)(IEEE Cat. No. 04CH37566): volume 3. [S.l.]: IEEE, 2004: 2301-2306.
- [21]PARK S U, CHUNG M J. Extrinsic calibration between a 3d laser scanner and a camera using pca method[C]//2012 9th International Conference on Ubiquitous Robots and Ambient Intelligence (URAI). [S.l.]: IEEE, 2012: 527-528.
- [22]UNNIKRISHNAN R, HEBERT M. Fast extrinsic calibration of a laser rangefinder to a camera[J]. *Robotics Institute, Pittsburgh, PA, Tech. Rep. CMU-RI-TR-05-09*, 2005.
- [23]韩正勇, 卜春光, 刘宸. 一种针孔相机与三维激光雷达外参标定方法[J]. *传感器与微系统*, 2018, 37 (4): 9-12.
- [24]RANGESH A, YUEN K, SATZODAR K, et al. A multimodal, full-surround

- vehicular testbed for naturalistic studies and benchmarking: Design, calibration and deployment[J]. arXiv preprint arXiv:1709.07502, 2017.
- [25] RANGESH A, YUEN K, SATZODAR K, et al. A multimodal, full-surround vehicular testbed for naturalistic studies and benchmarking: Design, calibration and deployment[J]. arXiv preprint arXiv:1709.07502, 2017.
- [26] WANG Z, LIU Y, LIAO Q, et al. Characterization of a rs-lidar for 3d perception[C]//2018 IEEE 8th Annual International Conference on CYBER Technology in Automation, Control, and Intelligent Systems (CYBER). [S.l.]: IEEE, 2018: 564-569.
- [27] LOWE D G. Distinctive image features from scale-invariant keypoints[J]. International journal of computer vision, 2004, 60 (2): 91-110.
- [28] BAY H, TUYTELAARS T, VAN GOOL L. Surf: Speeded up robust features[C]//European conference on computer vision. [S.l.]: Springer, 2006: 404-417.
- [29] RUBLEE E, RABAUD V, KONOLIGE K, et al. Orb: An efficient alternative to sift or surf.[C]//ICCV: volume 11. [S.l.]: Citeseer, 2011: 2.
- [30] HARTLEY R, ZISSERMAN A. Multiple view geometry in computer vision[M]. [S.l.]: Cambridge university press, 2003.
- [31] QUIGLEY M, CONLEY K, GERKEY B, et al. Ros: an open-source robot operating system[C]//ICRA workshop on open source software: volume 3. [S.l.]: Kobe, Japan, 2009: 5.
- [32] 高翔. 视觉 slam 十四讲: 从理论到实践[M]. [S.l.]: 电子工业出版社, 2017.
- [33] ZHANG Z, HANSON A R. 3d reconstruction based on homography mapping[J]. Proc. ARPA96, 1996: 1007-1012.
- [34] MALIS E, VARGAS M. Deeper understanding of the homography decomposition for vision-based control[D]. [S.l.]: INRIA, 2007.
- [35] SORKINE O. Least-squares rigid motion using svd[J]. Technical notes, 2009, 120 (3): 52.
- [36] TRIGGS B, MCLAUCHLAN P F, HARTLEY R I, et al. Bundle adjustment 欵攢 modern synthesis[C]//International workshop on vision algorithms. [S.l.]: Springer, 1999: 298-372.

- [37]胡昭民. 图解数据结构: 使用 C++[M]. [S.l.]: 清华大学出版社, 2016.
- [38]WALCOTT-BRYANT A, KAESS M, JOHANNSSON H, et al. Dynamic pose graph slam: Long-term mapping in low dynamic environments[C]//2012 IEEE/RSJ International Conference on Intelligent Robots and Systems. [S.l.]: IEEE, 2012: 1871-1878.
- [39]VARADARAJAN V S. Lie groups, lie algebras, and their representations: volume 102[M]. [S.l.]: Springer Science & Business Media, 2013.
- [40]DORSCH R G, HÄUSLER G, HERRMANN J M. Laser triangulation: fundamental uncertainty in distance measurement[J]. Applied optics, 1994, 33 (7): 1306-1314.
- [41]HAKALA T, SUOMALAINEN J, KAASALAINEN S, et al. Full waveform hyperspectral lidar for terrestrial laser scanning[J]. Optics express, 2012, 20 (7): 7119-7127.
- [42]ZHOU K, HOU Q, WANG R, et al. Real-time kd-tree construction on graphics hardware[C]//ACM Transactions on Graphics (TOG): volume 27. [S.l.]: ACM, 2008: 126.
- [43]FISCHLER M A, BOLLES R C. Random sample consensus: a paradigm for model fitting with applications to image analysis and automated cartography[J]. Communications of the ACM, 1981, 24 (6): 381-395.
- [44]HARRIS C G, STEPHENS M, et al. A combined corner and edge detector.[C]//Alvey vision conference: volume 15. [S.l.]: Citeseer, 1988: 10-5244.
- [45]LIU H, MOTODA H. Feature extraction, construction and selection: A data mining perspective: volume 453[M]. [S.l.]: Springer Science & Business Media, 1998.

哈尔滨工业大学学位论文原创性声明和使用权限

学位论文原创性声明

本人郑重声明：此处所提交的学位论文《激光雷达和多相机融合的智能标定方法研究》，是本人在导师指导下，在哈尔滨工业大学攻读学位期间独立进行研究工作所取得的成果，且学位论文中除已标注引用文献的部分外不包含他人完成或已发表的研究成果。对本学位论文的研究工作做出重要贡献的个人和集体，均已在文中以明确方式注明。

作者签名：王晨宇 日期：2019年6月21日

学位论文使用权限

学位论文是研究生在哈尔滨工业大学攻读学位期间完成的成果，知识产权归属哈尔滨工业大学。学位论文的使用权限如下：

(1) 学校可以采用影印、缩印或其他复制手段保存研究生上交的学位论文，并向国家图书馆报送学位论文；(2) 学校可以将学位论文部分或全部内容编入有关数据库进行检索和提供相应阅览服务；(3) 研究生毕业后发表与此学位论文研究成果相关的学术论文和其他成果时，应征得导师同意，且第一署名单位为哈尔滨工业大学。

保密论文在保密期内遵守有关保密规定，解密后适用于此使用权限规定。

本人知悉学位论文的使用权限，并将遵守有关规定。

作者签名：王晨宇 日期：2019年6月21日
导师签名：费中阳 日期：2019年6月22日

致 谢

感谢国家给我这个来自贫困山区的学生一个读研究生的机会，让我认识了很多优秀的同学、室友。他们让我看到了比优秀更优秀的同学是如何学习、如何平衡生活和学业的。

感谢高会军老师给我营造了一个安静舒适的实验室环境，让我们可以更专心于科研和学习。感谢林伟阳老师两年来的帮助，帮助我们查找论文中的错误，教会我使用和配置 Emacs 这个非常好用的工具。

感谢费中阳老师给我论文提出宝贵意见，纠正我对科研的态度。是我研究生路上的一座灯塔，照亮我的科研道路。

感谢实验室的叶超学长给我毕业论文提供整体的思路，教会了我如何对一个题目收集资料、开展科研以及很多处理科研中困难的方法和技巧。

感谢实验室的欧阳毅、张宏斌、周天添同学，是你们让原本枯燥无味的科研变得有了乐趣。在欢笑中我们完成了两年的研究生学习，这一段一定是我人生中最难忘的日子。谢谢大家每天不计前嫌的开玩笑，以及开玩笑后在依然认真的科研，在学习上互相帮助。感谢实验室的师弟余兆鸿、孟令波在我去深圳学习的时候帮助我照顾我的鱼。

感谢我的室友赵鹏辉、尹国梁、董坦坦，感谢你们营造了一个良好的寝室氛围，保证每天充足的休息以及偶尔的小聚会讲讲最近的苦与乐。

感谢任慧铭同学在我研究生阶段给我莫大的支持。在我学习迷茫无助的时候鼓励我支持我，让我又重拾信心投入到学习中。

最后，感谢父母和爷爷奶奶对我学业无怨无悔的支持。感谢你们的辛勤付出让我在学习的路上没有后顾之忧。